

Funktionaler pathway-zentrierter medizinischer Wissensgraph mit Ausschlusslogik

Eine systemmedizinische Architektur zur Unterstützung der
Differentialdiagnose

Lukas Geiger

Unabhängiger Forscher, Bernau, Deutschland

ORCID: <https://orcid.org/0009-0005-7296-1534>

Maerz 2026 — Konzeptpapier v0.2

Zusammenfassung

Wir stellen den Entwurf und die prototypische Implementierung eines funktionalen pathway-zentrierten medizinischen Wissensgraphen vor, der die Differentialdiagnose unterstützen soll. Herkömmliche klinische Entscheidungsunterstützungssysteme organisieren Wissen um Diagnosen, Symptome oder Gene als primäre Entitäten. Im Gegensatz dazu verwendet das vorgeschlagene System *biologische funktionelle Pathways* als zentrales Ordnungsprinzip, wobei Gene, Proteine, Laborwerte, anatomische Lokalisationen, Zelltypen und klinische Diagnosen als sekundäre Annotationen verknüpft werden.

Diese Architektur ermöglicht eine neuartige Form des *Ausschlusschliessens*: Wenn ein funktioneller Pathway nachweislich intakt ist (über normale Labormarker), können alle Gene, die für diesen Pathway essentiell und hinreichend sind, als primäre Krankheitsursachen beim aktuellen Patienten ausgeschlossen werden. Das System ist als SQLite-gestützter Prototyp mit einer grafischen PySide6-Oberfläche implementiert und integriert öffentliche Datenquellen (Reactome, Gene Ontology, UniProt, HGNC, Uberon, Cell Ontology).

Wir beschreiben das formale Ausschlussmodell – sowohl in binärer als auch in probabilistischer Variante – seine Annahmen und Einschränkungen und schlagen ein Validierungsframework vor. Der Prototyp wird an einem Hämolysen-Immundefizienz-Szenario demonstriert, das fünf funktionelle Pathways, elf Gene und sieben Labormarker umfasst. Das System ist als Forschungswerkzeug zur Erkundung des pathway-zentrierten Paradigmas positioniert, nicht als klinisches Entscheidungsunterstützungssystem.

Schlüsselwörter: Wissensgraph, Differentialdiagnose, funktionelle Pathways, Ausschlusslogik, Systemmedizin, Reactome, Gene Ontology

1 Einleitung und Motivation

Die Differentialdiagnose bei komplexen Multisystemerkrankungen scheitert haeufig nicht am Mangel an Daten, sondern an der Unfaehigkeit, heterogene Evidenz systematisch zu integrieren. Ein Patient mit abnormalen Laborwerten kann Hunderte genetischer Kandidatenursachen haben; aktuelle klinische Werkzeuge praesentieren diese groesstenteils als Ranglisten, ohne die logische Struktur *ausgeschlossener* Moeglichkeiten auszunutzen.

Die zentrale Beobachtung, die diese Arbeit motiviert, lautet:

Wenn ein biologischer funktioneller Pathway nachweislich intakt ist, dann koennen alle Gene, die fuer diesen Pathway sowohl notwendig als auch hinreichend sind, als primaere Ursachen einer Funktionsstoerung ausgeschlossen werden.

Dies transformiert positive Evidenz (intakter Pathway) in negative diagnostische Einschraenkungen (ausgeschlossene Gene) und kann den Kandidatenraum erheblich reduzieren, bevor die Differentialdiagnose angewendet wird.

Bestehende Systeme organisieren Wissen unterschiedlich. PhenoTips ([Girdea et al., 2013](#)) und Phenomizer ([Köhler et al., 2009](#)) gleichen Patientenphaenotypen ueber die Human Phenotype Ontology ([Robinson et al., 2008](#)) mit Krankheitsdatenbanken ab. Diese Systeme sind hervorragend im Symptom-Krankheits-Abgleich, nutzen aber nicht die Pathway-Integritaet als Ausschlussbeleg. Pathway-Datenbanken wie Reactome ([Fabregat et al., 2018](#)) und KEGG organisieren sich um biochemische Reaktionen, sind aber nicht fuer klinisches Ausschlusschliessen konzipiert. Gene Ontology ([Ashburner et al., 2000](#)) liefert feingranulare Prozessbeschreibungen, es fehlt jedoch der klinische Entscheidungsrahmen.

Das vorgeschlagene System schliesst diese Luecke, indem es funktionelle Pathways als *erstrangige Entitaeten* in einem Wissensgraphen behandelt, wobei alle anderen biomedizinischen Konzepte – Gene, anatomische Lokalisationen, Zelltypen, Labormarker und Diagnosen – als sekundaere Annotationen angebunden werden. Diese strukturelle Entscheidung ermoeglicht eine formale Ausschlusslogik, die sowohl rechnerisch handhabbar als auch biologisch sinnvoll ist.

1.1 Beitraege

1. Ein **Datenmodell**, das funktionelle Pathways als zentrales Ordnungsprinzip fuer klinisches Schliessen verwendet und sechs Entitaetstypen ueber semantisch typisierte Kanten verknuepft.
2. Ein **formales Ausschlussframework** mit sowohl binaerer als auch probabilistischer Variante, das die systematische Eliminierung von Kandidatengenomen auf Basis von Pathway-Integritaetsevidenz ermoeglicht.
3. Eine **prototypische Implementierung** mit Datenaufnahme aus sechs oeffentlichen biologischen Datenbanken, einem interaktiven Graphen-Explorer und einer Diagnoseabfrage-Engine.
4. Ein **Validierungsframework**, das Metriken, Benchmark-Anforderungen und Vergleichskriterien zur Bewertung des Ansatzes spezifiziert.

2 Problemstellung und formale Hypothese

2.1 Formale Problemstellung

Sei $\mathcal{P} = \{p_1, \dots, p_n\}$ die Menge der biologischen funktionellen Pathways fuer einen gegebenen Patientenkontext. Sei $\mathcal{G}$ die Menge der Kandidatengene. Sei $\mathcal{E}(p_i) \subseteq \mathcal{G}$ die Menge der fuer Pathway p_i *essentiellen* Gene. Sei $s(p_i) \in \{0, 1\}$ der beobachtete Pathway-Status: 1 = intakt, 0 = gestoert oder unbekannt.

Definition 1 (Binaere Ausschlussregel). *Wenn $s(p_i) = 1$, dann gilt $\forall g \in \mathcal{E}(p_i)$: Gen g ist als primaere Krankheitsursache ausgeschlossen, sofern g nur in Pathways essentiell ist, die alle intakt sind:*

$$\text{excluded}(g) \iff \forall p_i \text{ s.t. } g \in \mathcal{E}(p_i) : s(p_i) = 1 \quad (1)$$

Definition 2 (Probabilistischer Ausschlusswert). *Fuer ein Gen g ist die Ausschlusskonfidenz:*

$$\text{excl}(g) = \prod_{i: g \in \mathcal{E}(p_i)} c(p_i) \cdot b(g) \quad (2)$$

wobei $c(p_i) \in [0, 1]$ die Pathway-Statuskonfidenz ist (intakt: 0,95, unbekannt: 0,50, gestoert: 0,05) und $b(g) \in [0, 1]$ ein Multi-Pathway-Bonusfaktor:

$$b(g) = \min\left(1.0, 0.7 + 0.1 \cdot |\{p_i : g \in \mathcal{E}(p_i) \wedge s(p_i) = 1\}|\right) \quad (3)$$

Der Verdachtswert beruecksichtigt die Genredundanz:

$$\text{susp}(g) = (1 - \text{excl}(g)) \cdot r(g) \quad (4)$$

wobei $r(g) \in \{1.0, 0.85, 0.6, 0.3\}$ den Redundanzgrad des Gens abbildet (keine, gering, mittel, hoch).

2.2 Kernhypothese

Pathway-statusbasierte Ausschlusslogik reduziert die Kandidatengenmenge bei komplexen seltenen Erkrankungen systematisch um mindestens 30 % gegenueber rein phaenotypbasierter Filterung, wenn sie auf einem kuratierten Benchmark-Datensatz evaluiert wird.

Dies ist eine spezifische, falsifizierbare Hypothese. Die 30 %-Schwelle ist als minimale klinisch bedeutsame Reduktion gesetzt; ein Nullergebnis ($< 10\%$ Reduktion) wuerde darauf hinweisen, dass die Ausschlusslogik ueber bestehende Werkzeuge hinaus wenig diagnostischen Mehrwert bietet.

Die Kandidatenreduktionsrate (CRR) ist definiert als:

$$\text{CRR} = 1 - \frac{|\mathcal{G}_{\text{after exclusion}}|}{|\mathcal{G}_{\text{before exclusion}}|} \quad (5)$$

3 Systemarchitektur

3.1 Datenmodell

Die zentrale Entitaet ist der **FunctionalPathway**-Knoten, der einen diskreten biologischen Prozess mit beobachtbaren Ein- und Ausgaben repraesentiert. Abbildung 1 zeigt das vollstaendige Datenmodell.




Abbildung 1: Entity-Relationship-Diagramm des pathway-zentrierten Wissensgraphen. Durchgezogene Pfeile zeigen primaere Beziehungen ueber den Pathway-Hub; gestrichelte Pfeile zeigen sekundaere Querverbindungen.

Jeder Entitaetstyp traegt domaaensspezifische Attribute:

- **FunctionalPathway**: Name, Beschreibung, primaere Ausgabe, Zeitklasse (akut/chronisch), Status (intakt/gestoert/unbekannt), externe ID (Reactome oder GO).
- **BodyLocation** (Uberon): Organ, Subkompartiment, Zirkulationstyp, Immunrolle.
- **CellType** (Cell Ontology): Linie, Reifungsstadium, Lebensdauer, Mobilitaet.
- **Gene/Protein** (HGNC/UniProt): Symbol, Funktionstyp (strukturell, regulatorisch, signalgebend, metabolisch), Redundanzgrad, Expressionsorte.
- **MeasurementType**: Name, LOINC-Code, Referenzbereich, Messort, Sensitivitaet, Spezifitaet.
- **ClinicalDiagnosis**: Name, ICD-10-Code, Beschreibung.

Kantentypen tragen semantische Bezeichnungen (Tabelle 1) und bei Gen-Pathway-Kanten ein `is_essential`-Flag, das modulatorische von essentiellen Genbeitraegen unterscheidet.

Tabelle 1: Semantische Kantentypen im Wissensgraphen.

Quelle	Ziel	Relation
Pathway	BodyLocation	OCCURS_IN
Pathway	CellType	EXECUTED_BY
Gene	Pathway	REQUIRES (essentiell) / MODULATES
Measurement	Pathway	MONITORS_OUTPUT_OF
Measurement	BodyLocation	REPRESENTS_ACTIVITY_IN
Pathway	Diagnosis	DISRUPTION_LEADS_TO
Gene	BodyLocation	EXPRESSED_IN

3.2 Implementierung

Der Prototyp verwendet **SQLite** als Backend, wobei relationale Tabellen eine Graphstruktur ueber Assoziationstabellen simulieren (Abbildung 2). Das System umfasst vier Hauptmodule:

1. **Aufnahmemodul:** Laedt sechs oeffentliche Datenquellen herunter und parst sie (Abschnitt 3.3), mit einem manifestbasierten Tracking-System zur Vermeidung redundanter Downloads.
2. **Engine-Modul:** Implementiert die Ausschlusslogik (binaer und probabilistisch), Graphtraversierungsabfragen, Mustererkennung fuer Messwert-Signaturen und die Erzeugung menschenlesbarer Erklaerungen.
3. **GUI-Modul:** Eine PySide6-basierte Desktop-Anwendung mit vier Tabs: Graph Explorer (interaktive Netzwerkvisualisierung ueber NetworkX), Ausschluss-Panel (Pathway-Statusverwaltung und -analyse), Diagnoseabfrage (messwertgesteuerte Hypothesengenerierung) und Datenbrowser (Rohtabelleninspektion).
4. **Datenbankmodul:** Schemadefinition, CRUD-Hilfsfunktionen und Kantenverknuepfungsfunktionen mit Fremdschlüsselconstraints.




Abbildung 2: Relationales SQLite-Schema. Graue Kaesten sind Entitaetstabellen; blaue Kaesten sind Assoziations-(Kanten-)Tabellen mit Fremdschlüsseln.

Ein dedizierter **Graph Explorer** (NetworkX-basiert) visualisiert Teilgraphen mit lazy-geladenen Nachbarschaften. Das Graph-Layout wird in einem Hintergrund-Thread berechnet, um die GUI-Responsivitaet zu erhalten. Knoten sind nach Entitaetstyp farbco-dierte; Pathway-Knoten zeigen zusaetzlich ihren Status (intakt/gestoert/unbekannt) durch Randfarben an.

Hinweis zur Wahl der Graphdatenbank. Die aktuelle SQLite-Implementierung er-moeglicht schnelles Prototyping, fuehrt aber zu bekannten Einschränkungen bei tiefer Graphtraversierung (siehe Abschnitt 6). Ein Produktivsystem wuerde von Neo4j oder ei-ner vergleichbaren nativen Graphdatenbank profitieren. Der Prototyp demonstriert das konzeptuelle Modell; Leistungsvergleiche mit graphnativen Backends sind geplant.

3.3 Datenquellen

Das System integriert sechs oeffentliche biologische Datenbanken, die jeweils einen spezi-fischen Entitaetstyp zum Wissensgraphen beitragen:

Tabelle 2: Integrierte Datenquellen und ihre Rollen.

Quelle	Entitaetstyp	Format	Status
Reactome (Fabregat et al., 2018)	Pathways, Reaktionen	TSV	Integriert
Gene Ontology (Ashburner et al., 2000)	Biologische Prozesse	OBO, GAF	Integriert
UniProt (The UniProt Consortium, 2023)	Proteine, Gen-Links	TSV	Integriert
HGNC (Braschi et al., 2019)	Gennomenklatur	TSV	Integriert
Uberon (Mungall et al., 2012)	Anatomische Lokalisationen	OBO	Integriert
Cell Ontology (Diehl et al., 2016)	Zelltypen	OBO	Integriert
OMIM / HPO (Robinson et al., 2008)	Krankheit-Gen-Links	—	Geplant

Die Datenaufnahme folgt einer definierten Reihenfolge (HGNC $\rightarrow$ Uberon $\rightarrow$ Cell Ontology $\rightarrow$ UniProt $\rightarrow$ Reactome $\rightarrow$ GO), um Fremdschluesselabhaengigkeiten zu er-fuellen. Jede Quelle wird ueber eine Manifestdatei verfolgt, die Download-Zeitstempel, SHA-256-Pruefsummen und Importstatus aufzeichnet.

4 Ausschlusslogik

4.1 Binaerer Ausschluss

Die binaere Ausschluss-Engine (Definition 1) iteriert ueber alle Gene, die in mindestens einem Pathway als essentiell markiert sind. Fuer jedes Gen werden alle Pathways abge-rufen, in denen das Gen essentiell ist, und es wird geprueft, ob *alle* dieser Pathways den Status „intakt“ haben. Ist dies der Fall, wird das Gen ausgeschlossen; andernfalls bleibt es ein Kandidat.

Algorithm 1 Binaere Ausschlussanalyse

Require: Menge von Pathways $\mathcal{P}$ mit Status $s(p_i)$, essentielle Gen-Zuordnung $\mathcal{E}$

Ensure: Mengen $\mathcal{G}_{\text{excluded}}$, $\mathcal{G}_{\text{candidate}}$

```
1:  $\mathcal{I} \leftarrow \{p_i \in \mathcal{P} : s(p_i) = \text{intakt}\}$ 
2: for all  $g \in \bigcup_{p \in \mathcal{P}} \mathcal{E}(p)$  do ▷ Alle essentiellen Gene
3:    $P_g \leftarrow \{p \in \mathcal{P} : g \in \mathcal{E}(p)\}$  ▷ Pathways, die  $g$  benoetigen
4:   if  $P_g \subseteq \mathcal{I}$  und  $P_g \neq \emptyset$  then
5:      $\mathcal{G}_{\text{excluded}} \leftarrow \mathcal{G}_{\text{excluded}} \cup \{g\}$ 
6:   else
7:      $\mathcal{G}_{\text{candidate}} \leftarrow \mathcal{G}_{\text{candidate}} \cup \{g\}$ 
8:   end if
9: end for
```

Die Konfidenz des Ausschlusses haengt von der Anzahl intakter Pathways ab: Ein Gen, das ueber mehrere unabhaengige intakte Pathways ausgeschlossen wird, hat staerkere Evidenz als eines, das ueber einen einzelnen Pathway ausgeschlossen wird.

4.2 Probabilistischer Ausschluss

Die probabilistische Engine (Definition 2) erweitert das binaere Modell durch Zuweisung kontinuierlicher Konfidenzwerte. Drei Faktoren tragen bei:

1. **Pathway-Evidenz:** Jeder Pathway-Status wird auf einen Konfidenzwert abgebildet (intakt: 0,95, unbekannt: 0,50, gestoert: 0,05). Die kombinierte Pathway-Konfidenz fuer ein Gen ist das Produkt ueber alle seine essentiellen Pathways.
2. **Multi-Pathway-Bonus:** Gene, die in mehreren intakten Pathways essentiell sind, erhalten einen Bonusfaktor, der die staerkere Evidenz aus unabhaengigen Quellen widerspiegelt.
3. **Redundanzgewichtung:** Der Verdachtswert wird durch den Redundanzgrad des Gens moduliert. Gene ohne funktionelle Absicherung (Redundanz = „keine“) erhalten volles Verdachtsgewicht ($r = 1,0$); hoch redundante Gene erhalten reduziertes Gewicht ($r = 0,3$).

Gene werden nach Ausschlusskonfidenz kategorisiert: hoch ($\geq 0,8$), moderat (0,3–0,8) oder verdaechtig ($< 0,3$). Diese dreiteilige Klassifikation bietet Klinikern eine priorisierte Rangliste anstelle einer binaeren Entscheidung.

4.3 Mustererkennung

Zusaetzlich zum Ausschlusssschliessen implementiert das System eine **Messwert-Signaturerkennung**. Eine Signatur ist ein vordefiniertes Muster abnormaler Laborwerte (z. B. „Haemolyse-Signatur“: niedriges Haptoglobin + hohes LDH + hohes indirektes Bilirubin + hohe Retikulozyten + niedriges Haemoglobin). Jede Komponente traegt ein Gewicht, das ihre diagnostische Bedeutung widerspiegelt.

Bei einer Menge abnormaler Messwerte berechnet das System einen gewichteten Uebereinstimmungswert gegen alle definierten Signaturen:

$$\text{match}(S) = \frac{\sum_{c \in S_{\text{matched}}} w_c}{\sum_{c \in S_{\text{all}}} w_c} \quad (6)$$

Signaturen mit $\text{match} \geq 0,3$ werden gemeldet, was eine schnelle Identifikation bekannter klinischer Muster ermöglicht.

5 Demonstration: Haemolyse-Immundefizienz-Szenario

Der Prototyp enthaelt einen kuratierten Seed-Datensatz, der die Ueberschneidung von hereditaerer Sphaerozytose, autoimmunhaemolytischer Anaemie und Agammaglobulinaemie modelliert. Dieses Szenario wurde gewaehlt, weil es mehrere interagierende Pathways mit gemeinsamen anatomischen Lokalisationen (Milz, Knochenmark) umfasst und die Ausschlusslogik ueber unabhaengige funktionelle Domaenen hinweg demonstriert.

5.1 Funktionelle Pathways

Fuenf Pathways werden modelliert (Tabelle 3), die zwei klinische Domaenen (Haematologie und Immunologie) mit unterschiedlichen zeitlichen Charakteristiken umfassen.

Tabelle 3: Funktionelle Pathways im Demonstrationsszenario.

Pathway	Ausgabe	Zeitlich
Erythrozytenmembran-Integritaet	Stabile bikonkave Erythrozyten	Chronisch
Erythrozytenabbau (Haemolyse)	Freies Hb $\rightarrow$ Bilirubin	Akut
Milzfiltration	Entfernung defekter Zellen	Akut
Fruehe B-Zell-Differenzierung	Funktionelle Prae-B-Zellen	Chronisch
Antikoerperproduktion	IgG, IgM, IgA	Beides

5.2 Gen-Pathway-Essentialitaet

Elf Gene sind mit diesen Pathways verknuepft, mit expliziten Essentialitaetsannotationen (Tabelle 4). Das Essentialitaetsflag ist das entscheidende Attribut, das die Ausschlusslogik ermöglicht: Nur essentielle Gene koennen ausgeschlossen werden, wenn ihr Pathway intakt ist.

Tabelle 4: Gene und ihre Pathway-Essentialitaet im Demonstrationsszenario.

Gen	Pathway	Essentiell	Redundanz
ANK1	Membranintegritaet	Ja	Keine
SLC4A1	Membranintegritaet	Ja	Keine
SPTA1	Membranintegritaet	Ja	Gering
SPTB	Membranintegritaet	Ja	Keine
EPB42	Membranintegritaet	Ja	Gering
HMOX1	Haemolyse	Ja	Gering
HP	Haemolyse	Nein	Gering
BLNK	B-Zell-Differenzierung	Ja	Keine
CD19	B-Zell-Differenzierung	Ja	Keine
PAX5	B-Zell-Differenzierung	Ja	Keine
NOTCH2	Milzfiltration, B-Zell-Diff.	Ja / Nein	Gering

5.3 Ausschlusszenario

Betrachten wir einen Patienten mit folgender Präsentation:

- Niedriges Haemoglobin (Anaemie)
- Niedriges Haptoglobin (Haemolyse-Marker)
- Hohes LDH, hohes indirektes Bilirubin (Haemolyse)
- Normale B-Zell-Zahl (CD19+)
- Normale IgG-Spiegel

Das System leitet ab:

1. Normale B-Zell-Zahl $\Rightarrow$ B-Zell-Differenzierungs-Pathway *intakt* $\Rightarrow$ **Ausschluss** von BLNK, CD19, PAX5.
2. Normales IgG $\Rightarrow$ Antikörperproduktions-Pathway *intakt*.
3. Haemolyse-Marker abnormal $\Rightarrow$ Haemolyse-Pathway *gestoert*.
4. NOTCH2 ist essentiell in der Milzfiltration (Status unbekannt) und nicht-essentiell in der B-Zell-Differenzierung $\Rightarrow$ **bleibt Kandidat**.
5. Membrangene (ANK1, SLC4A1, SPTA1, SPTB, EPB42) sind nur im Membranintegritäts-Pathway essentiell (Status unbekannt/gestoert) $\Rightarrow$ **bleiben Kandidaten**.

Ergebnis: 3 von 10 essentiellen Genen ausgeschlossen (CRR = 30 %), was der Hypothesenschwelle entspricht. Die verbleibenden Kandidaten umfassen korrekt die membranstrukturellen Gene, die mit hereditärer Sphaerozytose assoziiert sind.

6 Annahmen und Einschränkungen

6.1 Unabhangigkeitsannahme

Das binaere Ausschlussmodell nimmt an, dass Pathways *funktionell unabhangig* sind: Ein intakter Pathway p_i schliesst seine essentiellen Gene unabhangig vom Status anderer Pathways aus. Diese Annahme ist **bekanntermassen falsch** in vielen biologischen Kontexten:

- Viele Gene sind in mehreren Pathways beteiligt (*Pleiotropie*). Ein ueber Pathway p_i ausgeschlossenes Gen koennte dennoch ueber einen anderen Pathway p_j , der nicht erfasst wird, ursaechlich sein. Das Modell adressiert dies, indem es verlangt, dass *alle* Pathways eines Gens intakt sein muessen, bevor ein Ausschluss erfolgt.
- Kompensationsmechanismen koennen die gemessenen Pathway-Ausgaben aufrechterhalten, selbst wenn ein essentielles Gen teilweise dysfunktional ist.
- Der binaere Status $s(p_i) \in \{0, 1\}$ ist eine Vereinfachung; die reale Pathway-Aktivitaet existiert auf einem Kontinuum.

Das probabilistische Modell mildert diese Einschrankungen teilweise durch kontinuierliche Konfidenzwerte, aber die Gewichtsparameter werden derzeit heuristisch zugewiesen.

6.2 Definition der Essentialitaet

„Essentielles Gen“ ist operationell definiert als ein Gen, das in Reactome oder kuratierten Quellen als *erforderlich* fuer mindestens eine Reaktion im Pathway annotiert ist. Diese Definition ist konservativ und sollte unter Verwendung kuratierter Essentialitaetsdatenbanken (z. B. DepMap, CRISPR-Essentialitaetsscreens) verfeinert werden.

6.3 Datenbank-Backend

Die SQLite-Implementierung genuegt fuer den aktuellen Prototyp (~17 MB Datenbank, <2000 Pathways), fuehrt aber zu Einschränkungen bei der Vollskalierung:

- Tiefe Graphtraversierungen (Tiefe > 3) erfordern mehrfache JOIN-Operationen, die schlecht skalieren.
- Keine native Unterstuetzung fuer Kuerzeste-Wege- oder Musterabgleich-Abfragen, die in Graphdatenbanken verfuegbar sind (z. B. Neo4j Cypher).
- Gleichzeitiger Schreibzugriff ist durch SQLites Dateisperrung auf Dateiebene limitiert.

6.4 Datenvollstaendigkeit

Nicht alle Pathways haben eine ausreichende Reactome-Abdeckung. Verwaiste Pathways, gewebespezifischer Metabolismus und kuerzlich charakterisierte Mechanismen sind moeglicherweise nicht repraesentiert. Die Gene-Ontology-Integration erhoeht die Breite, jedoch auf Kosten der Granularitaet – viele GO-Begriffe fuer biologische Prozesse sind zu generisch, um als aussagekraeftige funktionelle Pathways zu dienen.

6.5 EHR-Interoperabilitaet

Ein praktischer Einsatz ausschlussbasierter klinischer Entscheidungsunterstuetzung erfordert die Integration mit elektronischen Gesundheitsaktensystemen (EHR), um strukturierte Laborwerte des Patienten zu erhalten. Ohne interoperablen Zugang zu Echtzeit-Laborwerten ueber Standards wie HL7 FHIR bleibt das System auf manuell eingegebene Messwerte beschraenkt. EHR-Interoperabilitaet ist eine gut dokumentierte Herausforderung in der klinischen Informatik; ihre Loesung liegt ausserhalb des Rahmens dieses Konzeptpapiers, stellt aber eine kritische Anforderung fuer jede zukuenftige klinische Anwendung dar.

6.6 Messredundanz und Kontextualitaet

Die probabilistische Ausschlussformel (Definition 2) nimmt an, dass Labormessungen unabhaengige Evidenz ueber den Pathway-Status liefern. Jedoch warnt das Contextuality-by-Default-(CbD-)Framework von Dzhafarov und Kujala ([Dzhafarov and Kujala, 2016](#)), dass parallele Messungen informationelle Redundanz statt genuiner Unabhaengigkeit aufweisen koennen. Wenn zwei Laborwerte gleichzeitig abfallen, kann dies eine redundante Messung derselben Pathway-Ausgabe widerspiegeln, anstatt unabhaengige Evidenz fuer eine gemeinsame genetische Ursache (Pleiotropie) darzustellen. Eine rigorose Behandlung wuerde einen CbD-inspirierten Korrekturterm im Ausschlusswert erfordern, der die

Ueberlappung des Messkontexts beruecksichtigt. Diese Verfeinerung ist fuer zukuenftige Versionen des probabilistischen Modells geplant.

7 Verwandte Arbeiten

7.1 Phaenotypgesteuerte Diagnoseunterstuetzung

Phenomizer (Köhler et al., 2009) und PhenoTips (Girdea et al., 2013) repraesentieren den Stand der Technik in der phaenotypgesteuerten Diagnose. Beide Systeme gleichen Patientenphaenotypen (HPO-Terme) mit Krankheitsdatenbanken ab und ordnen Kandidatendiagnosen nach semantischer Aehnlichkeit. Sie sind effektiv beim Symptom-Krankheits-Abgleich, modellieren aber keine biologischen Pathways und nutzen die Pathway-Integritaet nicht fuer Ausschlusschliessen.

7.2 Pathway-Analyse in der Genomik

Gene Set Enrichment Analysis (GSEA) (Subramanian et al., 2005) und verwandte Werkzeuge identifizieren dysregulierte Pathways aus Expressionsdaten. Diese Methoden arbeiten auf Populationsebene und erfordern Omics-Daten, die in der klinischen Routineversorgung typischerweise nicht verfuegbar sind. Das vorgeschlagene System arbeitet mit individuellen Laborwerten des Patienten und ist daher in klinischen Standardarbeitsablaeufen anwendbar.

7.3 Graphbasiertes klinisches Schliessen

Wissensgraphen fuer die klinische Entscheidungsunterstuetzung wurden in verschiedenen Kontexten untersucht. Klinische Wissensgraphen aus elektronischen Gesundheitsakten (Rotmensch et al., 2017) erfassen statistische Assoziationen zwischen Diagnosen, Laborwerten und Behandlungen. Grossskalige biomedizinische Wissensgraphen wie Hetionet (Himmelstein et al., 2017) integrieren diverse Datenquellen fuer Drug-Repurposing und Hypothesengenerierung. Keines dieser Systeme nutzt jedoch den Pathway-Status als erst-rangige Einschraenkung im Ausschlusschliessen.

7.4 LLM-gestuetztes biomedizinisches Schliessen

Neuere Arbeiten kombinieren grosse Sprachmodelle mit biomedizinischen Wissensgraphen. ESCARGOT (Matsumoto et al., 2025) integriert LLMs mit einer dynamischen „Graph of Thoughts“-Architektur und biomedizinischen Wissensgraphen fuer Multihop-Schlussfolgerungsaufgaben. Waehrend ESCARGOT effektives graphbasiertes Schliessen in biomedizinischen Kontexten demonstriert, arbeitet es als Allzweck-Schlussfolgerungsagent ohne explizite Ausschlusslogik. Das vorgeschlagene System teilt die Betonung des wissensgraphgesteuerten Schliessens, unterscheidet sich aber grundlegend in seinem Ordnungsprinzip: funktionelle Pathways als erst-rangige diagnostische Einschraenkungen statt allgemeiner Graphtraversierung.

HealthGenie (Gao et al., 2025) demonstriert wissensgetriebene LLM-Integration fuer personalisierte Gesundheitsberatung. Sein Ansatz organisiert Wissensgraphen um Benutzerprofile und Ernaehrungsempfehlungen – eine symptomzentrierte (oder bedarfszentrierte) Organisation. Im Gegensatz dazu organisiert das vorgeschlagene System um biologi-

sche funktionelle Pathways, was mechanistisches Ausschlusschliessen ermoeeglicht, das in symptomzentrierten Architekturen nicht verfuegbar ist.

7.5 Vergleichszusammenfassung

Tabelle 5: Vergleich des vorgeschlagenen Systems mit verwandten Ansaetzen.

System	Primaere Entitaet	Ausschluss	Laborwerte	Pathways
Phenomizer	HPO-Phaenotypen	Nein	Nein	Nein
PhenoTips	Patientenphaenotypen	Nein	Begrenzt	Nein
GSEA/KEGG	Pathways	Nein	Nur Omics	Ja
Hetionet	Heterogen	Nein	Nein	Teilweise
Klinische KGs	EHR-Daten	Nein	Ja	Nein
ESCARGOT	KG + LLM	Nein	Nein	Teilweise
HealthGenie	KG + LLM	Nein	Nein	Nein
Vorgeschlagen	Pathways	Ja	Ja	Ja

8 Evaluationsframework

8.1 Benchmark-Datensatz

Eine rigorose Validierung erfordert einen kuratierten Benchmark von 20–50 bestaetigten genetischen Diagnosen, bei denen:

1. Laborprofile des Patienten zum Zeitpunkt der Erstvorstellung (vor der genetischen Diagnose) vorliegen.
2. Die genetische Diagnose bestaetigt ist (Variante + Phaenotyp + funktionelle Studie).
3. Der Pathway-Status des Patienten retrospektiv aus Labordaten rekonstruiert werden kann.

Zielquellen umfassen Register fuer seltene Erkrankungen (EURORDIS), klinische Synopsen aus OMIM und publizierte Fallserien mit umfassenden Laboruntersuchungen.

8.2 Primaere Metrik

Die Kandidatenreduktionsrate (CRR, Gleichung 5) dient als primaeres Erfolgskriterium. Ein $CRR > 0,30$ unterstuetzt die Kernhypothese; ein $CRR < 0,10$ wuerde auf unzureichenden diagnostischen Mehrwert hinweisen.

Sicherheitseinschraenkung: Das bestaetigte ursaechliche Gen darf *niemals* ausgeschlossen werden (Falschausschlussrate = 0). Jeder Falschausschluss im Benchmark invalidiert das Modell fuer die klinische Anwendung.

8.3 Alternative Validierung: Synthetische Patientenpersonas

Ein alternativer Validierungsweg adressiert den Mangel an annotierten realen Datensätzen für seltene Erkrankungen. LLM-generierte synthetische Patientenpersonas können durch gezielte Störungen im Pathway-Graphen konstruiert werden – beispielsweise durch Simulation eines ANK1-Defekts, indem der Erythrozytenmembranintegritäts-Pathway auf „gestört“ gesetzt wird und konsistente Laborwerte abgeleitet werden. Da das ursächliche Gen *a priori* definiert ist, kann die Ausschluss-Engine mit exakter Grundwahrheit evaluiert werden: Das System muss nicht-ursächliche Gene ausschliessen (Messung der CRR) und darf das eingepflanzte ursächliche Gen niemals ausschliessen (Messung der Falschausschlussrate). Dieser Ansatz ergänzt den Realfall-Benchmark und ermöglicht systematisches Testen über ein breiteres Spektrum von Krankheitsszenarien, als möglicherweise aus Registern allein verfügbar ist.

8.4 Sekundäre Metriken

- **Rangverbesserung:** Position des korrekten Gens in der Rangkandidatenliste nach Ausschlussfilterung.
- **Abdeckung:** Prozentsatz der Benchmark-Fälle, bei denen mindestens ein Pathway anhand verfügbarer Labordaten bewertet werden kann.
- **Vergleich:** CRR gegenüber standardmässiger HPO-only-Filterung auf dem gleichen Fallsatz.

9 Diskussion

Der pathway-zentrierte Ansatz adressiert eine strukturelle Lücke in der aktuellen klinischen Entscheidungsunterstützung: die systematische Nutzung *negativer Evidenz* (was nachweislich funktioniert), um den diagnostischen Raum einzuschränken. Dies ist konzeptionell analog zur industriellen Fehlerdiagnose, bei der funktionierende Subsysteme ganze Äste des Fehlerbaums eliminieren.

Mehrere Designentscheidungen verdienen Diskussion:

Warum Pathways als Zentrum, nicht Gene oder Diagnosen? Gene sind Ursachen; Diagnosen sind Folgen. Keines von beiden bietet die mechanistische Zwischenschicht, die für Ausschlussentscheidungen benötigt wird. Pathways repräsentieren die funktionellen Einheiten, die genetische Ursachen mit klinischen Auswirkungen verbinden, und sind damit der natürliche Drehpunkt für sowohl Einschluss- als auch Ausschlusslogik.

Binaerer vs. probabilistischer Ausschluss. Das binaere Modell ist konzeptionell einfacher und leichter zu validieren (ein Gen ist entweder ausgeschlossen oder nicht), kann aber keine Unsicherheit ausdrücken. Das probabilistische Modell erfasst abgestufte Evidenz, erfordert jedoch kalibrierte Parameter. Wir empfehlen das binaere Modell für die initiale Validierung und das probabilistische Modell für die klinische Erkundung.

Skalierbarkeit. Der aktuelle Prototyp bewaeltigt das Demonstrationsszenario (~ 50 Knoten, ~ 80 Kanten) ohne Leistungsprobleme. Die Skalierung auf die vollstaendige Reactome-Datenbank (> 2400 Pathways, $> 10\,000$ Reaktionen) wird Leistungstests und wahrscheinlich eine Migration zu einer Graphdatenbank-Backend erfordern.

10 Fazit und zukuenftige Arbeiten

Der funktionale pathway-zentrierte Wissensgraph repraesentiert einen strukturell eigenstaendigen Ansatz zur Differentialdiagnose-Unterstuetzung, der Pathway-Status-Evidenz als explizite diagnostische Einschränkungen nutzt. Die prototypische Implementierung demonstriert die Machbarkeit ueber alle Kernkomponenten hinweg: Datenaufnahme aus sechs oeffentlichen Datenbanken, Graphmodellierung mit semantischen Kantentypen, binäeres und probabilistisches Ausschlusschliessen, Mustererkennung und interaktive Visualisierung.

Die Kernhypothese – dass Pathway-Ausschluss den Kandidatengenraum um $\geq 30\%$ ohne Falschausschluesse reduziert – ist testbar und stellt das primaere empirische Ziel fuer zukuenftige Arbeiten dar.

10.1 Zentrale offene Aufgaben

1. **Benchmark-Datensatz:** Kuratierung von 20–50 Faellen aus Registern fuer seltene Erkrankungen mit Laborprofilen und bestaetigten genetischen Diagnosen.
2. **Gewichtskalibrierung:** Entwicklung einer datengetriebenen Methode zur Schaetzung der Pathway-Konfidenzgewichte $c(p_i)$ aus Messzuverlaessigkeit und Pathway-Redundanz.
3. **OMIM/HPO-Integration:** Verknuepfung von Krankheit-Gen-Assoziationen aus OMIM und HPO-Annotationen, um einen direkten Vergleich mit rein phaenotyp-basierter Filterung zu ermoeglichen.
4. **Graphdatenbank-Migration:** Evaluation von Neo4j oder aehnlichen Backends fuer Skalierbarkeit ueber den SQLite-Prototyp hinaus.
5. **Vergleich mit klinischen Werkzeugen:** Benchmark gegen Phenomizer auf demselben Fallsatz zur Quantifizierung des Mehrwerts pathway-zentrierten Ausschlusses.
6. **Temporale Modellierung:** Erweiterung des Frameworks zur Erfassung der Krankheitsprogression und zeitabhaengiger Pathway-Statusaenderungen.

Daten- und Softwareverfuegbarkeit

Der Quellcode des Prototyps, einschliesslich Datenbankschema, Aufnahmepipelines, Ausschluss-Engines und GUI-Anwendung, ist als Open-Source-Software verfuegbar. Das System integriert ausschliesslich oeffentliche Datenquellen; es werden keine Patientendaten verwendet oder benoetigt.

KI-Offenlegung

Bei der Erstellung dieses Manuskripts wurden KI-gestuetzte Werkzeuge (Claude, Anthropic) eingesetzt, insbesondere fuer Literaturrecherche, Unterstuetzung bei der Codeentwicklung, Textstrukturierung und Uebersetzungshilfe. Der konzeptuelle Entwurf, die wissenschaftliche Argumentation, die formale Modellentwicklung und die Verantwortung fuer alle Inhalte liegen ausschliesslich beim Autor.

Literatur

- Ashburner, M., Ball, C. A., Blake, J. A., Botstein, D., Butler, H., Cherry, J. M., Davis, A. P., Dolinski, K., Dwight, S. S., Eppig, J. T., Harris, M. A., Hill, D. P., Issel-Tarver, L., Kasarskis, A., Lewis, S., Matese, J. C., Richardson, J. E., Ringwald, M., Rubin, G. M., and Sherlock, G. (2000). Gene Ontology: tool for the unification of biology. *Nature Genetics*, 25(1):25–29.
- Braschi, B., Denny, P., Gray, K., Jones, T., Seal, R., Tweedie, S., Yates, B., and Bruford, E. (2019). Genenames.org: the HGNC and VGNC resources in 2019. *Nucleic Acids Research*, 47(D1):D786–D792.
- Diehl, A. D., Meehan, T. F., Bradford, Y. M., Brush, M. H., Dahdul, W. M., Dougall, D. S., He, Y., Osumi-Sutherland, D., Ruttenberg, A., Sarntivijai, S., Van Slyke, C. E., Vasilevsky, N. A., Haendel, M. A., Blake, J. A., and Mungall, C. J. (2016). The Cell Ontology 2016: enhanced content, modularization, and ontology interoperability. *Journal of Biomedical Semantics*, 7(1):44.
- Dzhafarov, E. N. and Kujala, J. V. (2016). Context-content systems of random variables: The contextuality-by-default theory. *Journal of Mathematical Psychology*, 74:11–33.
- Fabregat, A., Jupe, S., Matthews, L., Sidiropoulos, K., Gillespie, M., Garapati, P., Haw, R., Jassal, B., Korber, F., May, B., Milacic, M., Roca, C. D., Rothfels, K., Sevilla, C., Shamovsky, V., Shorser, S., Varusai, T., Viteri, G., Weiser, J., Wu, G., Stein, L., Hermjakob, H., and D’Eustachio, P. (2018). The Reactome pathway knowledgebase. *Nucleic Acids Research*, 46(D1):D649–D655.
- Gao, F., Zhao, X., Xia, D., Zhou, Z., Yang, R., Lu, J., Jiang, H., Park, C., and Li, I. (2025). HealthGenie: A knowledge-driven LLM framework for tailored dietary guidance. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*, CIKM ’25, pages 6639–6643. ACM.
- Girdea, M., Dumitriu, S., Fiume, M., Bowdin, S., Bhatt, K., Boycott, K. M., and Brudno, M. (2013). PhenoTips: Patient phenotyping software for clinical and research use. *Human Mutation*, 34(8):1057–1065.
- Himmelstein, D. S., Lizée, A., Hessler, C., Brueggeman, L., Chen, S. L., Hadley, D., Green, A., Khankhanian, P., and Baranzini, S. E. (2017). Systematic integration of biomedical knowledge prioritizes drugs for repurposing. *eLife*, 6:e26726.
- Köhler, S., Schulz, M. H., Krawitz, P., Bauer, S., Dölken, S., Ott, C. E., Mundlos, S., Horn, D., Mundlos, S., and Robinson, P. N. (2009). Clinical diagnostics in human

- genetics with semantic similarity searches in ontologies. *American Journal of Human Genetics*, 85(4):457–464.
- Matsumoto, N., Choi, H., Moran, J., Hernandez, M. E., Venkatesan, M., Li, X., Chang, J.-H., Wang, P., and Moore, J. H. (2025). ESCARGOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning. *Bioinformatics*, 41(2).
- Mungall, C. J., Torniai, C., Gkoutos, G. V., Lewis, S. E., and Haendel, M. A. (2012). Uberon, an integrative multi-species anatomy ontology. *Genome Biology*, 13(1):R5.
- Robinson, P. N., Köhler, S., Bauer, S., Seelow, D., Horn, D., and Mundlos, S. (2008). The Human Phenotype Ontology: a tool for annotating and analyzing human hereditary disease. *American Journal of Human Genetics*, 83(5):610–615.
- Rotmensch, M., Halpern, Y., Tlimat, A., Horng, S., and Sontag, D. (2017). Learning a health knowledge graph from electronic medical records. *Scientific Reports*, 7(1):5994.
- Subramanian, A., Tamayo, P., Mootha, V. K., Mukherjee, S., Ebert, B. L., Gillette, M. A., Paulovich, A., Pomeroy, S. L., Golub, T. R., Lander, E. S., and Mesirov, J. P. (2005). Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles. *Proceedings of the National Academy of Sciences*, 102(43):15545–15550.
- The UniProt Consortium (2023). UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Research*, 51(D1):D523–D531.