

Functional Pathway-Centric Medical Knowledge Graph with Exclusion Logic

A System-Medicine Architecture for Differential Diagnosis Support
(Mit deutscher Übersetzung im Anhang / With German translation in appendix)

Lukas Geiger

Independent Researcher, Bernau, Germany

ORCID: <https://orcid.org/0009-0005-7296-1534>

March 2026 — Concept Paper v0.2 (Combined EN/DE)

Abstract

We present the design and prototype implementation of a functional pathway-centric medical knowledge graph intended to support differential diagnosis. Standard clinical decision support systems organize knowledge around diagnoses, symptoms, or genes as primary entities. In contrast, the proposed system uses *biological functional pathways* as its central organizing principle, linking genes, proteins, laboratory values, anatomical locations, cell types, and clinical diagnoses as secondary annotations.

This architecture enables a novel form of *exclusion reasoning*: if a functional pathway is demonstrated to be intact (via normal laboratory markers), all genes essential and sufficient for that pathway can be excluded as primary causes of disease in the current patient. The system is implemented as a SQLite-backed prototype with a PySide6 graphical interface, integrating public data sources (Reactome, Gene Ontology, UniProt, HGNC, Uberon, Cell Ontology).

We describe the formal exclusion model—both binary and probabilistic variants—its assumptions and limitations, and propose a validation framework. The prototype is demonstrated on a hemolysis-immunodeficiency scenario involving five functional pathways, eleven genes, and seven laboratory markers. The system is positioned as a research tool for exploring the pathway-centric paradigm, not as a clinical decision support system.

Keywords: knowledge graph, differential diagnosis, functional pathways, exclusion reasoning, system medicine, Reactome, Gene Ontology

1 Introduction and Motivation

Differential diagnosis in complex, multi-system diseases frequently fails not from lack of data but from the inability to systematically integrate heterogeneous evidence. A patient with abnormal laboratory values may have hundreds of candidate genetic causes; current

clinical tools largely present these as ranked lists without exploiting the logical structure of *excluded* possibilities.

The central observation motivating this work is:

If a biological functional pathway is demonstrably intact, then all genes that are both necessary and sufficient for that pathway can be excluded as primary causes of dysfunction.

This transforms positive evidence (intact pathway) into negative diagnostic constraints (excluded genes), potentially reducing the candidate space substantially before differential diagnosis is applied.

Existing systems organize knowledge differently. PhenoTips (Girdea et al., 2013) and Phenomizer (Köhler et al., 2009) match patient phenotypes to disease databases via the Human Phenotype Ontology (Robinson et al., 2008). These systems excel at symptom-to-disease matching but do not exploit pathway integrity as exclusion evidence. Pathway databases such as Reactome (Fabregat et al., 2018) and KEGG organize around biochemical reactions but are not designed for clinical exclusion reasoning. Gene Ontology (Ashburner et al., 2000) provides fine-grained process descriptions but lacks the clinical decision framework.

The proposed system bridges this gap by treating functional pathways as *first-class entities* in a knowledge graph, with all other biomedical concepts—genes, anatomical locations, cell types, laboratory markers, and diagnoses—attached as secondary annotations. This structural choice enables a formal exclusion logic that is both computationally tractable and biologically meaningful.

1.1 Contributions

1. A **data model** centering on functional pathways as the primary organizing principle for clinical reasoning, linking six entity types through semantically typed edges.
2. A **formal exclusion framework** with both binary and probabilistic variants, enabling systematic elimination of candidate genes based on pathway integrity evidence.
3. A **prototype implementation** with data ingestion from six public biological databases, an interactive graph explorer, and a diagnosis query engine.
4. A **validation framework** specifying metrics, benchmark requirements, and comparison criteria for evaluating the approach.

2 Problem Statement and Formal Hypothesis

2.1 Formal Problem Statement

Let $\mathcal{P} = \{p_1, \dots, p_n\}$ be the set of biological functional pathways for a given patient context. Let $\mathcal{G}$ be the set of candidate genes. Let $\mathcal{E}(p_i) \subseteq \mathcal{G}$ be the set of genes *essential* to pathway p_i . Let $s(p_i) \in \{0, 1\}$ be the observed pathway status: 1 = intact, 0 = disrupted or unknown.

Definition 1 (Binary Exclusion Rule). *If $s(p_i) = 1$, then $\forall g \in \mathcal{E}(p_i)$: gene g is excluded as a primary cause of disease, provided g is essential only in pathways that are all intact:*

$$\text{excluded}(g) \iff \forall p_i \text{ s.t. } g \in \mathcal{E}(p_i) : s(p_i) = 1 \quad (1)$$

Definition 2 (Probabilistic Exclusion Score). *For a gene g , the exclusion confidence is:*

$$\text{excl}(g) = \prod_{i: g \in \mathcal{E}(p_i)} c(p_i) \cdot b(g) \quad (2)$$

where $c(p_i) \in [0, 1]$ is the pathway status confidence (intact: 0.95, unknown: 0.50, disrupted: 0.05), and $b(g) \in [0, 1]$ is a multi-pathway bonus factor:

$$b(g) = \min\left(1.0, 0.7 + 0.1 \cdot |\{p_i : g \in \mathcal{E}(p_i) \wedge s(p_i) = 1\}|\right) \quad (3)$$

The suspicion score incorporates gene redundancy:

$$\text{susp}(g) = (1 - \text{excl}(g)) \cdot r(g) \quad (4)$$

where $r(g) \in \{1.0, 0.85, 0.6, 0.3\}$ maps the gene's redundancy degree (none, low, medium, high).

2.2 Core Hypothesis

Pathway-status-based exclusion logic systematically reduces the candidate gene set for complex rare disease cases by at least 30% relative to phenotype-only filtering, when evaluated on a curated benchmark dataset.

This is a specific, falsifiable hypothesis. The 30% threshold is set as a minimal clinically meaningful reduction; a null result ($< 10\%$ reduction) would indicate that the exclusion logic adds little diagnostic value beyond existing tools.

The candidate reduction rate (CRR) is defined as:

$$\text{CRR} = 1 - \frac{|\mathcal{G}_{\text{after exclusion}}|}{|\mathcal{G}_{\text{before exclusion}}|} \quad (5)$$

3 System Architecture

3.1 Data Model

The central entity is the **FunctionalPathway** node, representing a discrete biological process with observable inputs and outputs. Figure 1 illustrates the complete data model.




Figure 1: Entity-relationship diagram of the pathway-centric knowledge graph. Solid arrows indicate primary relationships through the pathway hub; dashed arrows indicate secondary cross-links.

Each entity type carries domain-specific attributes:

- **FunctionalPathway**: name, description, primary output, temporal class (acute/chronic), status (intact/disrupted/unknown), external ID (Reactome or GO).
- **BodyLocation** (Uberon): organ, subcompartment, circulation type, immune role.
- **CellType** (Cell Ontology): lineage, maturation stage, lifespan, mobility.
- **Gene/Protein** (HGNC/UniProt): symbol, function type (structural, regulatory, signaling, metabolic), redundancy degree, expression sites.
- **MeasurementType**: name, LOINC code, reference range, measurement site, sensitivity, specificity.
- **ClinicalDiagnosis**: name, ICD-10 code, description.

Edge types carry semantic labels (Table 1) and, for gene–pathway edges, an `is_essential` flag that distinguishes modulatory from essential gene contributions.

Table 1: Semantic edge types in the knowledge graph.

Source	Target	Relation
Pathway	BodyLocation	OCCURS_IN
Pathway	CellType	EXECUTED_BY
Gene	Pathway	REQUIRES (essential) / MODULATES
Measurement	Pathway	MONITORS_OUTPUT_OF
Measurement	BodyLocation	REPRESENTS_ACTIVITY_IN
Pathway	Diagnosis	DISRUPTION_LEADS_TO
Gene	BodyLocation	EXPRESSED_IN

3.2 Implementation

The prototype uses **SQLite** as the backend, with relational tables simulating a graph structure through association tables (Figure 2). The system comprises four main modules:

1. **Ingestion module:** Downloads and parses six public data sources (Section 3.3), with a manifest-based tracking system to avoid redundant downloads.
2. **Engine module:** Implements the exclusion logic (binary and probabilistic), graph traversal queries, pattern detection for measurement signatures, and human-readable explanation generation.
3. **GUI module:** A PySide6-based desktop application with four tabs: Graph Explorer (interactive network visualization via NetworkX), Exclusion Panel (pathway status management and analysis), Diagnosis Query (measurement-driven hypothesis generation), and Data Browser (raw table inspection).
4. **Database module:** Schema definition, CRUD helpers, and edge-linking functions with foreign key constraints.




Figure 2: SQLite relational schema. Gray boxes are entity tables; blue boxes are association (edge) tables with foreign keys.

A dedicated **Graph Explorer** (NetworkX-based) visualizes subgraphs with lazy-loaded neighborhoods. Graph layout is computed in a background thread to maintain GUI responsiveness. Nodes are color-coded by entity type; pathway nodes additionally display their status (intact/disrupted/unknown) through border colors.

Note on graph database choice. The current SQLite implementation enables rapid prototyping but introduces known limitations for deep graph traversal (see Section 6). A production system would benefit from Neo4j or a comparable native graph database. The prototype demonstrates the conceptual model; performance comparisons with graph-native backends are planned.

3.3 Data Sources

The system integrates six public biological databases, each contributing a specific entity type to the knowledge graph:

Table 2: Integrated data sources and their roles.

Source	Entity Type	Format	Status
Reactome (Fabregat et al., 2018)	Pathways, reactions	TSV	Integrated
Gene Ontology (Ashburner et al., 2000)	Biological processes	OBO, GAF	Integrated
UniProt (The UniProt Consortium, 2023)	Proteins, gene links	TSV	Integrated
HGNC (Braschi et al., 2019)	Gene nomenclature	TSV	Integrated
Uberon (Mungall et al., 2012)	Anatomical locations	OBO	Integrated
Cell Ontology (Diehl et al., 2016)	Cell types	OBO	Integrated
OMIM / HPO (Robinson et al., 2008)	Disease-gene links	—	Planned

Data ingestion follows a defined order (HGNC $\rightarrow$ Uberon $\rightarrow$ Cell Ontology $\rightarrow$ UniProt $\rightarrow$ Reactome $\rightarrow$ GO) to satisfy foreign key dependencies. Each source is tracked via a manifest file recording download timestamps, SHA-256 checksums, and import status.

4 Exclusion Logic

4.1 Binary Exclusion

The binary exclusion engine (Definition 1) iterates over all genes marked as essential in at least one pathway. For each gene, it retrieves all pathways where the gene is essential and checks whether *all* of these pathways have status “intact.” If so, the gene is excluded; otherwise, it remains a candidate.

Algorithm 1 Binary Exclusion Analysis

Require: Set of pathways $\mathcal{P}$ with status $s(p_i)$, essential gene mapping $\mathcal{E}$

Ensure: Sets $\mathcal{G}_{\text{excluded}}$, $\mathcal{G}_{\text{candidate}}$

```

1:  $\mathcal{I} \leftarrow \{p_i \in \mathcal{P} : s(p_i) = \text{intact}\}$ 
2: for all  $g \in \bigcup_{p \in \mathcal{P}} \mathcal{E}(p)$  do  $\triangleright$  All essential genes
3:    $P_g \leftarrow \{p \in \mathcal{P} : g \in \mathcal{E}(p)\}$   $\triangleright$  Pathways requiring  $g$ 
4:   if  $P_g \subseteq \mathcal{I}$  and  $P_g \neq \emptyset$  then
5:      $\mathcal{G}_{\text{excluded}} \leftarrow \mathcal{G}_{\text{excluded}} \cup \{g\}$ 
6:   else
7:      $\mathcal{G}_{\text{candidate}} \leftarrow \mathcal{G}_{\text{candidate}} \cup \{g\}$ 
8:   end if
9: end for
```

The confidence of exclusion depends on the number of intact pathways: a gene excluded via multiple independent intact pathways has stronger evidence than one excluded via a single pathway.

4.2 Probabilistic Exclusion

The probabilistic engine (Definition 2) extends the binary model by assigning continuous confidence scores. Three factors contribute:

1. **Pathway evidence:** Each pathway status maps to a confidence value (intact: 0.95, unknown: 0.50, disrupted: 0.05). The combined pathway confidence for a gene is the product over all its essential pathways.
2. **Multi-pathway bonus:** Genes essential in multiple intact pathways receive a bonus factor, reflecting stronger evidence from independent sources.
3. **Redundancy weighting:** The suspicion score is modulated by the gene’s redundancy degree. Genes with no functional backup (redundancy = “none”) receive full suspicion weight ($r = 1.0$); highly redundant genes receive reduced weight ($r = 0.3$).

Genes are categorized by exclusion confidence: high (≥ 0.8), moderate (0.3–0.8), or suspect (< 0.3). This tripartite classification provides clinicians with a ranked prioritization rather than a binary decision.

4.3 Pattern Detection

In addition to exclusion reasoning, the system implements **measurement signature detection**. A signature is a predefined pattern of abnormal laboratory values (e.g., “hemolysis signature”: low haptoglobin + high LDH + high indirect bilirubin + high reticulocytes + low hemoglobin). Each component carries a weight reflecting its diagnostic importance.

Given a set of abnormal measurements, the system computes a weighted match score against all defined signatures:

$$\text{match}(S) = \frac{\sum_{c \in S_{\text{matched}}} w_c}{\sum_{c \in S_{\text{all}}} w_c} \quad (6)$$

Signatures with $\text{match} \geq 0.3$ are reported, enabling rapid identification of known clinical patterns.

5 Demonstration: Hemolysis–Immunodeficiency Scenario

The prototype includes a curated seed dataset modeling the intersection of hereditary spherocytosis, autoimmune hemolytic anemia, and agammaglobulinemia. This scenario was chosen because it involves multiple interacting pathways with shared anatomical locations (spleen, bone marrow) and demonstrates the exclusion logic across independent functional domains.

5.1 Functional Pathways

Five pathways are modeled (Table 3), spanning two clinical domains (hematology and immunology) with distinct temporal characteristics.

Table 3: Functional pathways in the demonstration scenario.

Pathway	Output	Temporal
Erythrocyte membrane integrity	Stable biconcave RBCs	Chronic
Erythrocyte degradation (hemolysis)	Free Hb $\rightarrow$ bilirubin	Acute
Splenic filtration	Removal of defective cells	Acute
Early B-cell differentiation	Functional pre-B cells	Chronic
Antibody production	IgG, IgM, IgA	Both

5.2 Gene–Pathway Essentiality

Eleven genes are linked to these pathways with explicit essentiality annotations (Table 4). The essentiality flag is the critical attribute enabling exclusion logic: only essential genes can be excluded when their pathway is intact.

Table 4: Genes and their pathway essentiality in the demonstration scenario.

Gene	Pathway	Essential	Redundancy
ANK1	Membrane integrity	Yes	None
SLC4A1	Membrane integrity	Yes	None
SPTA1	Membrane integrity	Yes	Low
SPTB	Membrane integrity	Yes	None
EPB42	Membrane integrity	Yes	Low
HMOX1	Hemolysis	Yes	Low
HP	Hemolysis	No	Low
BLNK	B-cell differentiation	Yes	None
CD19	B-cell differentiation	Yes	None
PAX5	B-cell differentiation	Yes	None
NOTCH2	Splenic filtration, B-cell diff.	Yes / No	Low

5.3 Exclusion Scenario

Consider a patient presenting with:

- Low hemoglobin (anemia)
- Low haptoglobin (hemolysis marker)
- High LDH, high indirect bilirubin (hemolysis)
- Normal B-cell count (CD19+)
- Normal IgG levels

The system derives:

1. Normal B-cell count $\Rightarrow$ B-cell differentiation pathway *intact* $\Rightarrow$ **exclude** BLNK, CD19, PAX5.
2. Normal IgG $\Rightarrow$ antibody production pathway *intact*.

3. Hemolysis markers abnormal $\Rightarrow$ hemolysis pathway *disrupted*.
4. NOTCH2 is essential in splenic filtration (status unknown) and non-essential in B-cell differentiation $\Rightarrow$ **remains candidate**.
5. Membrane genes (ANK1, SLC4A1, SPTA1, SPTB, EPB42) are essential only in the membrane integrity pathway (status unknown/disrupted) $\Rightarrow$ **remain candidates**.

Result: 3 of 10 essential genes excluded (CRR = 30%), matching the hypothesis threshold. The remaining candidates correctly include the membrane-structural genes associated with hereditary spherocytosis.

6 Assumptions and Limitations

6.1 Independence Assumption

The binary exclusion model assumes that pathways are *functionally independent*: an intact pathway p_i excludes its essential genes regardless of the status of other pathways. This assumption is **known to be false** in many biological contexts:

- Many genes participate in multiple pathways (*pleiotropy*). A gene excluded via pathway p_i may still be causative via a different pathway p_j that is not assessed. The model addresses this by requiring *all* pathways of a gene to be intact before exclusion.
- Compensatory mechanisms can maintain measured pathway outputs even when an essential gene is partially dysfunctional.
- The binary status $s(p_i) \in \{0, 1\}$ is a simplification; real pathway activity exists on a continuum.

The probabilistic model partially mitigates these limitations through continuous confidence scores, but the weight parameters are currently assigned heuristically.

6.2 Essentiality Definition

“Essential gene” is defined operationally as a gene annotated in Reactome or curated sources as *required* for at least one reaction in the pathway. This definition is conservative and should be refined using curated essentiality databases (e.g., DepMap, CRISPR essentiality screens).

6.3 Database Backend

The SQLite implementation suffices for the current prototype (~ 17 MB database, < 2000 pathways) but introduces limitations for full-scale deployment:

- Deep graph traversals (depth > 3) require multiple JOIN operations that scale poorly.
- No native support for shortest-path or pattern-matching queries available in graph databases (e.g., Neo4j Cypher).
- Concurrent write access is limited by SQLite’s file-level locking.

6.4 Data Completeness

Not all pathways have adequate Reactome coverage. Orphan pathways, tissue-specific metabolism, and recently characterized mechanisms may not be represented. The Gene Ontology integration adds breadth but at the cost of granularity—many GO biological process terms are too generic to serve as meaningful functional pathways.

6.5 EHR Interoperability

A practical deployment of exclusion-based clinical decision support requires integration with electronic health record (EHR) systems to obtain structured patient laboratory data. Without interoperable access to real-time laboratory values via standards such as HL7 FHIR, the system remains limited to manually entered measurements. EHR interoperability is a well-documented challenge in clinical informatics; addressing it is beyond the scope of this concept paper but constitutes a critical requirement for any future clinical application.

6.6 Measurement Redundancy and Contextuality

The probabilistic exclusion formula (Definition 2) assumes that laboratory measurements provide independent evidence about pathway status. However, Dzhaferov and Kujala’s Contextuality-by-Default (CbD) framework (Dzhaferov and Kujala, 2016) warns that parallel measurements may exhibit informational redundancy rather than genuine independence. When two laboratory values decline simultaneously, this may reflect redundant measurement of the same pathway output rather than independent evidence of a shared genetic cause (pleiotropy). A rigorous treatment would require a CbD-inspired correction term in the exclusion score that accounts for measurement context overlap. This refinement is planned for future versions of the probabilistic model.

7 Related Work

7.1 Phenotype-Driven Diagnosis Support

Phenomizer (Köhler et al., 2009) and PhenoTips (Girdea et al., 2013) represent the state of the art in phenotype-driven diagnosis. Both systems match patient phenotypes (HPO terms) to disease databases and rank candidate diagnoses by semantic similarity. They are effective for symptom-to-disease matching but do not model biological pathways or exploit pathway integrity for exclusion reasoning.

7.2 Pathway Analysis in Genomics

Gene Set Enrichment Analysis (GSEA) (Subramanian et al., 2005) and related tools identify dysregulated pathways from expression data. These methods operate at the population level and require omics data not typically available in routine clinical settings. The proposed system works with individual patient laboratory values, making it applicable in standard clinical workflows.

7.3 Graph-Based Clinical Reasoning

Knowledge graphs for clinical decision support have been explored in several contexts. Clinical knowledge graphs built from electronic health records (Rotmensch et al., 2017) capture statistical associations between diagnoses, laboratory values, and treatments. Large-scale biomedical knowledge graphs such as Hetionet (Himmelstein et al., 2017) integrate diverse data sources for drug repurposing and hypothesis generation. However, none of these systems use pathway status as a first-class constraint in exclusion reasoning.

7.4 LLM-Augmented Biomedical Reasoning

Recent work combines large language models with biomedical knowledge graphs. ESCARGOT (Matsumoto et al., 2025) integrates LLMs with a dynamic “Graph of Thoughts” architecture and biomedical knowledge graphs for multihop reasoning tasks. While ESCARGOT demonstrates effective graph-based reasoning in biomedical contexts, it operates as a general-purpose reasoning agent without explicit exclusion logic. The proposed system shares the emphasis on knowledge graph-guided reasoning but differs fundamentally in its organizing principle: functional pathways as first-class diagnostic constraints rather than general-purpose graph traversal.

HealthGenie (Gao et al., 2025) demonstrates knowledge-driven LLM integration for personalized health guidance. Its approach organizes knowledge graphs around user profiles and dietary recommendations—a symptom-centric (or need-centric) organization. In contrast, the proposed system organizes around biological functional pathways, enabling mechanistic exclusion reasoning that is not available in symptom-centric architectures.

7.5 Comparison Summary

Table 5: Comparison of the proposed system with related approaches.

System	Primary Entity	Exclusion	Lab Values	Pathways
Phenomizer	HPO phenotypes	No	No	No
PhenoTips	Patient phenotypes	No	Limited	No
GSEA/KEGG	Pathways	No	Omics only	Yes
Hetionet	Heterogeneous	No	No	Partial
Clinical KGs	EHR data	No	Yes	No
ESCARGOT	KG + LLM	No	No	Partial
HealthGenie	KG + LLM	No	No	No
Proposed	Pathways	Yes	Yes	Yes

8 Evaluation Framework

8.1 Benchmark Dataset

A rigorous validation requires a curated benchmark of 20–50 confirmed genetic diagnoses where:

1. Patient laboratory profiles are available at the time of initial presentation (before genetic diagnosis).

2. The genetic diagnosis is confirmed (variant + phenotype + functional study).
3. The patient’s pathway status can be retrospectively reconstructed from laboratory data.

Target sources include rare disease registries (EURORDIS), OMIM clinical synopsis entries, and published case series with comprehensive laboratory workups.

8.2 Primary Metric

The candidate reduction rate (CRR, Equation 5) serves as the primary success criterion. A $CRR > 0.30$ supports the core hypothesis; a $CRR < 0.10$ would indicate insufficient diagnostic value.

Safety constraint: The confirmed causal gene must *never* be excluded (false exclusion rate = 0). Any false exclusion in the benchmark invalidates the model for clinical application.

8.3 Alternative Validation: Synthetic Patient Personas

An alternative validation pathway addresses the scarcity of annotated real-world datasets for rare diseases. LLM-generated synthetic patient personas can be constructed by introducing targeted perturbations in the pathway graph—for example, simulating an ANK1 defect by setting the erythrocyte membrane integrity pathway to “disrupted” and deriving consistent laboratory values. Since the causal gene is defined *a priori*, the exclusion engine can be evaluated with exact ground truth: the system must exclude non-causal genes (measuring CRR) while never excluding the planted causal gene (measuring false exclusion rate). This approach complements the real-case benchmark and permits systematic testing across a wider range of disease scenarios than may be available from registries alone.

8.4 Secondary Metrics

- **Rank improvement:** Position of the correct gene in the ranked candidate list after exclusion filtering.
- **Coverage:** Percentage of benchmark cases where at least one pathway can be assessed from available laboratory data.
- **Comparison:** CRR versus standard HPO-only filtering on the same case set.

9 Discussion

The pathway-centric approach addresses a structural gap in current clinical decision support: the systematic use of *negative evidence* (what is demonstrably working) to constrain the diagnostic space. This is conceptually analogous to industrial fault diagnosis, where functioning subsystems eliminate entire branches of the fault tree.

Several design decisions merit discussion:

Why pathways as center, not genes or diagnoses? Genes are causes; diagnoses are consequences. Neither provides the mechanistic intermediate layer needed for exclusion reasoning. Pathways represent the functional units that connect genetic causes to clinical effects, making them the natural pivot for both inclusion and exclusion logic.

Binary vs. probabilistic exclusion. The binary model is conceptually simpler and easier to validate (a gene is either excluded or not), but it cannot express uncertainty. The probabilistic model captures graded evidence but requires calibrated parameters. We recommend the binary model for initial validation and the probabilistic model for clinical exploration.

Scalability. The current prototype handles the demonstration scenario (~ 50 nodes, ~ 80 edges) without performance concerns. Scaling to the full Reactome database (> 2400 pathways, $> 10,000$ reactions) will require performance testing and likely a migration to a graph database backend.

10 Conclusion and Future Work

The functional pathway-centric knowledge graph represents a structurally distinct approach to differential diagnosis support, exploiting pathway-status evidence as explicit diagnostic constraints. The prototype implementation demonstrates feasibility across all core components: data ingestion from six public databases, graph modeling with semantic edge types, binary and probabilistic exclusion reasoning, pattern detection, and interactive visualization.

The core hypothesis—that pathway exclusion reduces the candidate gene space by $\geq 30\%$ without false exclusions—is testable and constitutes the primary empirical target for future work.

10.1 Key Open Tasks

1. **Benchmark dataset:** Curate 20–50 cases from rare disease registries with laboratory profiles and confirmed genetic diagnoses.
2. **Weight calibration:** Develop a data-driven method for estimating pathway confidence weights $c(p_i)$ from measurement reliability and pathway redundancy.
3. **OMIM/HPO integration:** Link disease–gene associations from OMIM and HPO annotations to enable direct comparison with phenotype-only filtering.
4. **Graph database migration:** Evaluate Neo4j or similar backends for scalability beyond the SQLite prototype.
5. **Clinical tool comparison:** Benchmark against Phenomizer on the same case set to quantify the added value of pathway-centric exclusion.
6. **Temporal modeling:** Extend the framework to capture disease progression and time-dependent pathway status changes.

Data and Software Availability

The prototype source code, including database schema, ingestion pipelines, exclusion engines, and GUI application, is available as open-source software. The system integrates exclusively public data sources; no patient data is used or required.

AI Disclosure

AI-assisted tools (Claude, Anthropic) were used in the preparation of this manuscript, particularly for literature research, code development support, text structuring, and translation assistance. The conceptual design, scientific argumentation, formal model development, and responsibility for all content lie exclusively with the author.

References

- Ashburner, M., Ball, C. A., Blake, J. A., Botstein, D., Butler, H., Cherry, J. M., Davis, A. P., Dolinski, K., Dwight, S. S., Eppig, J. T., Harris, M. A., Hill, D. P., Issel-Tarver, L., Kasarskis, A., Lewis, S., Matese, J. C., Richardson, J. E., Ringwald, M., Rubin, G. M., and Sherlock, G. (2000). Gene Ontology: tool for the unification of biology. *Nature Genetics*, 25(1):25–29.
- Braschi, B., Denny, P., Gray, K., Jones, T., Seal, R., Tweedie, S., Yates, B., and Bruford, E. (2019). Genenames.org: the HGNC and VGNC resources in 2019. *Nucleic Acids Research*, 47(D1):D786–D792.
- Diehl, A. D., Meehan, T. F., Bradford, Y. M., Brush, M. H., Dahdul, W. M., Dougall, D. S., He, Y., Osumi-Sutherland, D., Ruttenberg, A., Sarntivijai, S., Van Slyke, C. E., Vasilevsky, N. A., Haendel, M. A., Blake, J. A., and Mungall, C. J. (2016). The Cell Ontology 2016: enhanced content, modularization, and ontology interoperability. *Journal of Biomedical Semantics*, 7(1):44.
- Dzhafarov, E. N. and Kujala, J. V. (2016). Context-content systems of random variables: The contextuality-by-default theory. *Journal of Mathematical Psychology*, 74:11–33.
- Fabregat, A., Jupe, S., Matthews, L., Sidiropoulos, K., Gillespie, M., Garapati, P., Haw, R., Jassal, B., Korber, F., May, B., Milacic, M., Roca, C. D., Rothfels, K., Sevilla, C., Shamovsky, V., Shorser, S., Varusai, T., Viteri, G., Weiser, J., Wu, G., Stein, L., Hermjakob, H., and D’Eustachio, P. (2018). The Reactome pathway knowledgebase. *Nucleic Acids Research*, 46(D1):D649–D655.
- Gao, F., Zhao, X., Xia, D., Zhou, Z., Yang, R., Lu, J., Jiang, H., Park, C., and Li, I. (2025). HealthGenie: A knowledge-driven LLM framework for tailored dietary guidance. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*, CIKM ’25, pages 6639–6643. ACM.
- Girdea, M., Dumitriu, S., Fiume, M., Bowdin, S., Bhatt, K., Boycott, K. M., and Brudno, M. (2013). PhenoTips: Patient phenotyping software for clinical and research use. *Human Mutation*, 34(8):1057–1065.

- Himmelstein, D. S., Lizée, A., Hessler, C., Brueggeman, L., Chen, S. L., Hadley, D., Green, A., Khankhanian, P., and Baranzini, S. E. (2017). Systematic integration of biomedical knowledge prioritizes drugs for repurposing. *eLife*, 6:e26726.
- Köhler, S., Schulz, M. H., Krawitz, P., Bauer, S., Dölken, S., Ott, C. E., Mundlos, S., Horn, D., Mundlos, S., and Robinson, P. N. (2009). Clinical diagnostics in human genetics with semantic similarity searches in ontologies. *American Journal of Human Genetics*, 85(4):457–464.
- Matsumoto, N., Choi, H., Moran, J., Hernandez, M. E., Venkatesan, M., Li, X., Chang, J.-H., Wang, P., and Moore, J. H. (2025). ESCARGOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning. *Bioinformatics*, 41(2).
- Mungall, C. J., Torniai, C., Gkoutos, G. V., Lewis, S. E., and Haendel, M. A. (2012). Uberon, an integrative multi-species anatomy ontology. *Genome Biology*, 13(1):R5.
- Robinson, P. N., Köhler, S., Bauer, S., Seelow, D., Horn, D., and Mundlos, S. (2008). The Human Phenotype Ontology: a tool for annotating and analyzing human hereditary disease. *American Journal of Human Genetics*, 83(5):610–615.
- Rotmensch, M., Halpern, Y., Tlimat, A., Horng, S., and Sontag, D. (2017). Learning a health knowledge graph from electronic medical records. *Scientific Reports*, 7(1):5994.
- Subramanian, A., Tamayo, P., Mootha, V. K., Mukherjee, S., Ebert, B. L., Gillette, M. A., Paulovich, A., Pomeroy, S. L., Golub, T. R., Lander, E. S., and Mesirov, J. P. (2005). Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles. *Proceedings of the National Academy of Sciences*, 102(43):15545–15550.
- The UniProt Consortium (2023). UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Research*, 51(D1):D523–D531.

Anhang: Deutsche Übersetzung

Zusammenfassung

Wir stellen den Entwurf und die prototypische Implementierung eines funktionalen pathway-zentrierten medizinischen Wissensgraphen vor, der die Differentialdiagnose unterstützen soll. Herkömmliche klinische Entscheidungsunterstützungssysteme organisieren Wissen um Diagnosen, Symptome oder Gene als primäre Entitäten. Im Gegensatz dazu verwendet das vorgeschlagene System *biologische funktionelle Pathways* als zentrales Ordnungsprinzip, wobei Gene, Proteine, Laborwerte, anatomische Lokalisationen, Zelltypen und klinische Diagnosen als sekundäre Annotationen verknüpft werden.

Diese Architektur ermöglicht eine neuartige Form des *Ausschlusschliessens*: Wenn ein funktioneller Pathway nachweislich intakt ist (über normale Labormarker), können alle Gene, die für diesen Pathway essentiell und hinreichend sind, als primäre Krankheitsursachen beim aktuellen Patienten ausgeschlossen werden. Das System ist als SQLite-gestützter Prototyp mit einer grafischen PySide6-Oberfläche implementiert und integriert öffentliche Datenquellen (Reactome, Gene Ontology, UniProt, HGNC, Uberon, Cell Ontology).

Wir beschreiben das formale Ausschlussmodell – sowohl in binärer als auch in probabilistischer Variante – seine Annahmen und Einschränkungen und schlagen ein Validierungsframework vor. Der Prototyp wird an einem Hämolysen-Immundefizienz-Szenario demonstriert, das fünf funktionelle Pathways, elf Gene und sieben Labormarker umfasst. Das System ist als Forschungswerkzeug zur Erkundung des pathway-zentrierten Paradigmas positioniert, nicht als klinisches Entscheidungssystem.

Schlüsselwörter: Wissensgraph, Differentialdiagnose, funktionelle Pathways, Ausschlusslogik, Systemmedizin, Reactome, Gene Ontology

Einleitung und Motivation

Die Differentialdiagnose bei komplexen Multisystemerkrankungen scheitert häufig nicht am Mangel an Daten, sondern an der Unfähigkeit, heterogene Evidenz systematisch zu integrieren. Ein Patient mit abnormalen Laborwerten kann Hunderte genetischer Kandidatenursachen haben; aktuelle klinische Werkzeuge präsentieren diese größtenteils als Ranglisten, ohne die logische Struktur *ausgeschlossener* Möglichkeiten auszunutzen.

Die zentrale Beobachtung, die diese Arbeit motiviert, lautet:

Wenn ein biologischer funktioneller Pathway nachweislich intakt ist, dann können alle Gene, die für diesen Pathway sowohl notwendig als auch hinreichend sind, als primäre Ursachen einer Funktionsstörung ausgeschlossen werden.

Dies transformiert positive Evidenz (intakter Pathway) in negative diagnostische Einschränkungen (ausgeschlossene Gene) und kann den Kandidatenraum erheblich reduzieren, bevor die Differentialdiagnose angewendet wird.

Bestehende Systeme organisieren Wissen unterschiedlich. PhenoTips ([Girdea et al., 2013](#)) und Phenomizer ([Köhler et al., 2009](#)) gleichen Patientenphänotypen über die Human Phenotype Ontology ([Robinson et al., 2008](#)) mit Krankheitsdatenbanken ab. Diese Systeme sind hervorragend im Symptom-Krankheits-Abgleich, nutzen aber nicht die

Pathway-Integrität als Ausschlussbeleg. Pathway-Datenbanken wie Reactome (Fabregat et al., 2018) und KEGG organisieren sich um biochemische Reaktionen, sind aber nicht fuer klinisches Ausschluss-schliessen konzipiert. Gene Ontology (Ashburner et al., 2000) liefert feingranulare Prozessbeschreibungen, es fehlt jedoch der klinische Entscheidungsrahmen.

Das vorgeschlagene System schliesst diese Luecke, indem es funktionelle Pathways als *erstrangige Entitaeten* in einem Wissensgraphen behandelt, wobei alle anderen biomedizinischen Konzepte – Gene, anatomische Lokalisationen, Zelltypen, Labormarker und Diagnosen – als sekundäre Annotationen angebunden werden. Diese strukturelle Entscheidung ermoeeglicht eine formale Ausschlusslogik, die sowohl rechnerisch handhabbar als auch biologisch sinnvoll ist.

Beitraege

1. Ein **Datenmodell**, das funktionelle Pathways als zentrales Ordnungsprinzip fuer klinisches Schliessen verwendet und sechs Entitaetstypen ueber semantisch typisierte Kanten verknuepft.
2. Ein **formales Ausschlussframework** mit sowohl binaerer als auch probabilistischer Variante, das die systematische Eliminierung von Kandidatengenen auf Basis von Pathway-Integritaetsevidenz ermoeeglicht.
3. Eine **prototypische Implementierung** mit Datenaufnahme aus sechs oeffentlichen biologischen Datenbanken, einem interaktiven Graphen-Explorer und einer Diagnoseabfrage-Engine.
4. Ein **Validierungsframework**, das Metriken, Benchmark-Anforderungen und Vergleichskriterien zur Bewertung des Ansatzes spezifiziert.

Problemstellung und formale Hypothese

Formale Problemstellung

Sei $\mathcal{P} = \{p_1, \dots, p_n\}$ die Menge der biologischen funktionellen Pathways fuer einen gegebenen Patientenkontext. Sei $\mathcal{G}$ die Menge der Kandidatengene. Sei $\mathcal{E}(p_i) \subseteq \mathcal{G}$ die Menge der fuer Pathway p_i *essentiellen* Gene. Sei $s(p_i) \in \{0, 1\}$ der beobachtete Pathway-Status: 1 = intakt, 0 = gestoert oder unbekannt.

Definition 3 (Binaere Ausschlussregel). *Wenn $s(p_i) = 1$, dann gilt $\forall g \in \mathcal{E}(p_i)$: Gen g ist als primaere Krankheitsursache ausgeschlossen, sofern g nur in Pathways essentiell ist, die alle intakt sind:*

$$\text{excluded}(g) \iff \forall p_i \text{ s.t. } g \in \mathcal{E}(p_i) : s(p_i) = 1 \quad (7)$$

Definition 4 (Probabilistischer Ausschlusswert). *Fuer ein Gen g ist die Ausschlusskonfidenz:*

$$\text{excl}(g) = \prod_{i: g \in \mathcal{E}(p_i)} c(p_i) \cdot b(g) \quad (8)$$

wobei $c(p_i) \in [0, 1]$ die Pathway-Statuskonfidenz ist (intakt: 0,95, unbekannt: 0,50, gestoert: 0,05) und $b(g) \in [0, 1]$ ein Multi-Pathway-Bonusfaktor:

$$b(g) = \min\left(1.0, 0.7 + 0.1 \cdot |\{p_i : g \in \mathcal{E}(p_i) \wedge s(p_i) = 1\}|\right) \quad (9)$$

Der Verdachtswert beruecksichtigt die Genredundanz:

$$susp(g) = (1 - excl(g)) \cdot r(g) \quad (10)$$

wobei $r(g) \in \{1.0, 0.85, 0.6, 0.3\}$ den Redundanzgrad des Gens abbildet (keine, gering, mittel, hoch).

Kernhypothese

Pathway-statusbasierte Ausschlusslogik reduziert die Kandidatengenmenge bei komplexen seltenen Erkrankungen systematisch um mindestens 30 % gegenueber rein phaenotypbasierter Filterung, wenn sie auf einem kuratierten Benchmark-Datensatz evaluiert wird.

Dies ist eine spezifische, falsifizierbare Hypothese. Die 30 %-Schwelle ist als minimale klinisch bedeutsame Reduktion gesetzt; ein Nullergebnis ($< 10\%$ Reduktion) wuerde darauf hinweisen, dass die Ausschlusslogik ueber bestehende Werkzeuge hinaus wenig diagnostischen Mehrwert bietet.

Die Kandidatenreduktionsrate (CRR) ist definiert als:

$$CRR = 1 - \frac{|\mathcal{G}_{\text{after exclusion}}|}{|\mathcal{G}_{\text{before exclusion}}|} \quad (11)$$

Systemarchitektur

Datenmodell

Die zentrale Entitaet ist der **FunctionalPathway**-Knoten, der einen diskreten biologischen Prozess mit beobachtbaren Ein- und Ausgaben repraesentiert. Abbildung 3 zeigt das vollstaendige Datenmodell.




Abbildung 3: Entity-Relationship-Diagramm des pathway-zentrierten Wissensgraphen. Durchgezogene Pfeile zeigen primäre Beziehungen über den Pathway-Hub; gestrichelte Pfeile zeigen sekundäre Querverbindungen.

Jeder Entitätstyp trägt domänenspezifische Attribute:

- **FunctionalPathway**: Name, Beschreibung, primäre Ausgabe, Zeitklasse (akut/chronisch), Status (intakt/gestoert/unbekannt), externe ID (Reactome oder GO).
- **BodyLocation** (Uberon): Organ, Subkompartiment, Zirkulationstyp, Immunrolle.
- **CellType** (Cell Ontology): Linie, Reifungsstadium, Lebensdauer, Mobilität.
- **Gene/Protein** (HGNC/UniProt): Symbol, Funktionstyp (strukturell, regulatorisch, signalgebend, metabolisch), Redundanzgrad, Expressionsorte.
- **MeasurementType**: Name, LOINC-Code, Referenzbereich, Messort, Sensitivität, Spezifität.
- **ClinicalDiagnosis**: Name, ICD-10-Code, Beschreibung.

Kantentypen tragen semantische Bezeichnungen (Tabelle 6) und bei Gen-Pathway-Kanten ein `is_essential`-Flag, das modulatorische von essentiellen Genbeiträgen unterscheidet.

Tabelle 6: Semantische Kantentypen im Wissensgraphen.

Quelle	Ziel	Relation
Pathway	BodyLocation	OCCURS_IN
Pathway	CellType	EXECUTED_BY
Gene	Pathway	REQUIRES (essentiell) / MODULATES
Measurement	Pathway	MONITORS_OUTPUT_OF
Measurement	BodyLocation	REPRESENTS_ACTIVITY_IN
Pathway	Diagnosis	DISRUPTION_LEADS_TO
Gene	BodyLocation	EXPRESSED_IN

Implementierung

Der Prototyp verwendet **SQLite** als Backend, wobei relationale Tabellen eine Graphstruktur ueber Assoziationstabellen simulieren (Abbildung 4). Das System umfasst vier Hauptmodule:

1. **Aufnahmemodul:** Laedt sechs oeffentliche Datenquellen herunter und parst sie (Abschnitt 10.1), mit einem manifestbasierten Tracking-System zur Vermeidung redundanter Downloads.
2. **Engine-Modul:** Implementiert die Ausschlusslogik (binaer und probabilistisch), Graphtraversierungsabfragen, Mustererkennung fuer Messwert-Signaturen und die Erzeugung menschenlesbarer Erklaerungen.
3. **GUI-Modul:** Eine PySide6-basierte Desktop-Anwendung mit vier Tabs: Graph Explorer (interaktive Netzwerkvisualisierung ueber NetworkX), Ausschluss-Panel (Pathway-Statusverwaltung und -analyse), Diagnoseabfrage (messwertgesteuerte Hypothesengenerierung) und Datenbrowser (Rohtabelleninspektion).
4. **Datenbankmodul:** Schemadefinition, CRUD-Hilfsfunktionen und Kantenverknuepfungsfunktionen mit Fremdschlüsselconstraints.




Abbildung 4: Relationales SQLite-Schema. Graue Kaesten sind Entitaetstabellen; blaue Kaesten sind Assoziations-(Kanten-)Tabellen mit Fremdschluesseln.

Ein dedizierter **Graph Explorer** (NetworkX-basiert) visualisiert Teilgraphen mit lazy-geladenen Nachbarschaften. Das Graph-Layout wird in einem Hintergrund-Thread berechnet, um die GUI-Responsivitaet zu erhalten. Knoten sind nach Entitaetstyp farbco-dierte; Pathway-Knoten zeigen zusaetzlich ihren Status (intakt/gestoert/unbekannt) durch Randfarben an.

Hinweis zur Wahl der Graphdatenbank. Die aktuelle SQLite-Implementierung er-moeglicht schnelles Prototyping, fuehrt aber zu bekannten Einschränkungen bei tiefer Graphtraversierung (siehe Abschnitt 10.1). Ein Produktivsystem wuerde von Neo4j oder einer vergleichbaren nativen Graphdatenbank profitieren. Der Prototyp demonstriert das konzeptuelle Modell; Leistungsvergleiche mit graphnativen Backends sind geplant.

Datenquellen

Das System integriert sechs oeffentliche biologische Datenbanken, die jeweils einen spezi-fischen Entitaetstyp zum Wissensgraphen beitragen:

Tabelle 7: Integrierte Datenquellen und ihre Rollen.

Quelle	Entitaetstyp	Format	Status
Reactome (Fabregat et al., 2018)	Pathways, Reaktionen	TSV	Integriert
Gene Ontology (Ashburner et al., 2000)	Biologische Prozesse	OBO, GAF	Integriert
UniProt (The UniProt Consortium, 2023)	Proteine, Gen-Links	TSV	Integriert
HGNC (Braschi et al., 2019)	Gennomenklatur	TSV	Integriert
Uberon (Mungall et al., 2012)	Anatomische Lokalisationen	OBO	Integriert
Cell Ontology (Diehl et al., 2016)	Zelltypen	OBO	Integriert
OMIM / HPO (Robinson et al., 2008)	Krankheit-Gen-Links	—	Geplant

Die Datenaufnahme folgt einer definierten Reihenfolge (HGNC → Uberon → Cell Ontology → UniProt → Reactome → GO), um Fremdschluesselabhaengigkeiten zu er-fuellen. Jede Quelle wird ueber eine Manifestdatei verfolgt, die Download-Zeitstempel, SHA-256-Pruefsummen und Importstatus aufzeichnet.

Ausschlusslogik

Binaerer Ausschluss

Die binaere Ausschluss-Engine (Definition 3) iteriert ueber alle Gene, die in mindestens einem Pathway als essentiell markiert sind. Fuer jedes Gen werden alle Pathways abge-rufen, in denen das Gen essentiell ist, und es wird geprueft, ob *alle* dieser Pathways den Status „intakt“ haben. Ist dies der Fall, wird das Gen ausgeschlossen; andernfalls bleibt es ein Kandidat.

Algorithm 2 Binaere Ausschlussanalyse

Require: Menge von Pathways $\mathcal{P}$ mit Status $s(p_i)$, essentielle Gen-Zuordnung $\mathcal{E}$

Ensure: Mengen $\mathcal{G}_{\text{excluded}}$, $\mathcal{G}_{\text{candidate}}$

```
1:  $\mathcal{I} \leftarrow \{p_i \in \mathcal{P} : s(p_i) = \text{intakt}\}$ 
2: for all  $g \in \bigcup_{p \in \mathcal{P}} \mathcal{E}(p)$  do ▷ Alle essentiellen Gene
3:    $P_g \leftarrow \{p \in \mathcal{P} : g \in \mathcal{E}(p)\}$  ▷ Pathways, die  $g$  benoetigen
4:   if  $P_g \subseteq \mathcal{I}$  und  $P_g \neq \emptyset$  then
5:      $\mathcal{G}_{\text{excluded}} \leftarrow \mathcal{G}_{\text{excluded}} \cup \{g\}$ 
6:   else
7:      $\mathcal{G}_{\text{candidate}} \leftarrow \mathcal{G}_{\text{candidate}} \cup \{g\}$ 
8:   end if
9: end for
```

Die Konfidenz des Ausschlusses haengt von der Anzahl intakter Pathways ab: Ein Gen, das ueber mehrere unabhaengige intakte Pathways ausgeschlossen wird, hat staerkere Evidenz als eines, das ueber einen einzelnen Pathway ausgeschlossen wird.

Probabilistischer Ausschluss

Die probabilistische Engine (Definition 4) erweitert das binaere Modell durch Zuweisung kontinuierlicher Konfidenzwerte. Drei Faktoren tragen bei:

1. **Pathway-Evidenz:** Jeder Pathway-Status wird auf einen Konfidenzwert abgebildet (intakt: 0,95, unbekannt: 0,50, gestoert: 0,05). Die kombinierte Pathway-Konfidenz fuer ein Gen ist das Produkt ueber alle seine essentiellen Pathways.
2. **Multi-Pathway-Bonus:** Gene, die in mehreren intakten Pathways essentiell sind, erhalten einen Bonusfaktor, der die staerkere Evidenz aus unabhaengigen Quellen widerspiegelt.
3. **Redundanzgewichtung:** Der Verdachtswert wird durch den Redundanzgrad des Gens moduliert. Gene ohne funktionelle Absicherung (Redundanz = „keine“) erhalten volles Verdachtsgewicht ($r = 1,0$); hoch redundante Gene erhalten reduziertes Gewicht ($r = 0,3$).

Gene werden nach Ausschlusskonfidenz kategorisiert: hoch ($\geq 0,8$), moderat (0,3–0,8) oder verdaechtig ($< 0,3$). Diese dreiteilige Klassifikation bietet Klinikern eine priorisierte Rangliste anstelle einer binaeren Entscheidung.

Mustererkennung

Zusaetzlich zum Ausschlusssschliessen implementiert das System eine **Messwert-Signaturerkennung**. Eine Signatur ist ein vordefiniertes Muster abnormaler Laborwerte (z. B. „Haemolyse-Signatur“: niedriges Haptoglobin + hohes LDH + hohes indirektes Bilirubin + hohe Retikulozyten + niedriges Haemoglobin). Jede Komponente traegt ein Gewicht, das ihre diagnostische Bedeutung widerspiegelt.

Bei einer Menge abnormaler Messwerte berechnet das System einen gewichteten Uebereinstimmungswert gegen alle definierten Signaturen:

$$\text{match}(S) = \frac{\sum_{c \in S_{\text{matched}}} w_c}{\sum_{c \in S_{\text{all}}} w_c} \quad (12)$$

Signaturen mit $\text{match} \geq 0,3$ werden gemeldet, was eine schnelle Identifikation bekannter klinischer Muster ermöglicht.

Demonstration: Haemolyse-Immundefizienz-Szenario

Der Prototyp enthaelt einen kuratierten Seed-Datensatz, der die Ueberschneidung von hereditaerer Sphaerozytose, autoimmunhaemolytischer Anaemie und Agammaglobulinaemie modelliert. Dieses Szenario wurde gewaehlt, weil es mehrere interagierende Pathways mit gemeinsamen anatomischen Lokalisationen (Milz, Knochenmark) umfasst und die Ausschlusslogik ueber unabhaengige funktionelle Domaenen hinweg demonstriert.

Funktionelle Pathways

Fuenf Pathways werden modelliert (Tabelle 8), die zwei klinische Domaenen (Haematologie und Immunologie) mit unterschiedlichen zeitlichen Charakteristiken umfassen.

Tabelle 8: Funktionelle Pathways im Demonstrationsszenario.

Pathway	Ausgabe	Zeitlich
Erythrozytenmembran-Integritaet	Stabile bikonkave Erythrozyten	Chronisch
Erythrozytenabbau (Haemolyse)	Freies Hb $\rightarrow$ Bilirubin	Akut
Milzfiltration	Entfernung defekter Zellen	Akut
Fruehe B-Zell-Differenzierung	Funktionelle Prae-B-Zellen	Chronisch
Antikoerperproduktion	IgG, IgM, IgA	Beides

Gen-Pathway-Essentialitaet

Elf Gene sind mit diesen Pathways verknuepft, mit expliziten Essentialitaetsannotationen (Tabelle 9). Das Essentialitaetsflag ist das entscheidende Attribut, das die Ausschlusslogik ermöglicht: Nur essentielle Gene koennen ausgeschlossen werden, wenn ihr Pathway intakt ist.

Tabelle 9: Gene und ihre Pathway-Essentialitaet im Demonstrationsszenario.

Gen	Pathway	Essentiell	Redundanz
ANK1	Membranintegritaet	Ja	Keine
SLC4A1	Membranintegritaet	Ja	Keine
SPTA1	Membranintegritaet	Ja	Gering
SPTB	Membranintegritaet	Ja	Keine
EPB42	Membranintegritaet	Ja	Gering
HMOX1	Haemolyse	Ja	Gering
HP	Haemolyse	Nein	Gering
BLNK	B-Zell-Differenzierung	Ja	Keine
CD19	B-Zell-Differenzierung	Ja	Keine
PAX5	B-Zell-Differenzierung	Ja	Keine
NOTCH2	Milzfiltration, B-Zell-Diff.	Ja / Nein	Gering

Ausschlusszenario

Betrachten wir einen Patienten mit folgender Präsentation:

- Niedriges Haemoglobin (Anaemie)
- Niedriges Haptoglobin (Haemolyse-Marker)
- Hohes LDH, hohes indirektes Bilirubin (Haemolyse)
- Normale B-Zell-Zahl (CD19+)
- Normale IgG-Spiegel

Das System leitet ab:

1. Normale B-Zell-Zahl $\Rightarrow$ B-Zell-Differenzierungs-Pathway *intakt* $\Rightarrow$ **Ausschluss** von BLNK, CD19, PAX5.
2. Normales IgG $\Rightarrow$ Antikörperproduktions-Pathway *intakt*.
3. Haemolyse-Marker abnormal $\Rightarrow$ Haemolyse-Pathway *gestoert*.
4. NOTCH2 ist essentiell in der Milzfiltration (Status unbekannt) und nicht-essentiell in der B-Zell-Differenzierung $\Rightarrow$ **bleibt Kandidat**.
5. Membrangene (ANK1, SLC4A1, SPTA1, SPTB, EPB42) sind nur im Membranintegritäts-Pathway essentiell (Status unbekannt/gestoert) $\Rightarrow$ **bleiben Kandidaten**.

Ergebnis: 3 von 10 essentiellen Genen ausgeschlossen (CRR = 30 %), was der Hypothesenschwelle entspricht. Die verbleibenden Kandidaten umfassen korrekt die membranstrukturellen Gene, die mit hereditärer Sphärozytose assoziiert sind.

Annahmen und Einschränkungen

Unabhängigkeitsannahme

Das binäre Ausschlussmodell nimmt an, dass Pathways *funktionell unabhängig* sind: Ein intakter Pathway p_i schließt seine essentiellen Gene unabhängig vom Status anderer Pathways aus. Diese Annahme ist **bekanntermassen falsch** in vielen biologischen Kontexten:

- Viele Gene sind in mehreren Pathways beteiligt (*Pleiotropie*). Ein über Pathway p_i ausgeschlossenes Gen könnte dennoch über einen anderen Pathway p_j , der nicht erfasst wird, ursächlich sein. Das Modell adressiert dies, indem es verlangt, dass *alle* Pathways eines Gens intakt sein müssen, bevor ein Ausschluss erfolgt.
- Kompensationsmechanismen können die gemessenen Pathway-Ausgaben aufrechterhalten, selbst wenn ein essentielles Gen teilweise dysfunktional ist.
- Der binäre Status $s(p_i) \in \{0, 1\}$ ist eine Vereinfachung; die reale Pathway-Aktivität existiert auf einem Kontinuum.

Das probabilistische Modell mildert diese Einschränkungen teilweise durch kontinuierliche Konfidenzwerte, aber die Gewichtsparameter werden derzeit heuristisch zugewiesen.

Definition der Essentialitaet

„Essentielles Gen“ ist operationell definiert als ein Gen, das in Reactome oder kuratierten Quellen als *erforderlich* fuer mindestens eine Reaktion im Pathway annotiert ist. Diese Definition ist konservativ und sollte unter Verwendung kuratierter Essentialitaetsdatenbanken (z. B. DepMap, CRISPR-Essentialitaetsscreens) verfeinert werden.

Datenbank-Backend

Die SQLite-Implementierung genuegt fuer den aktuellen Prototyp (~17 MB Datenbank, <2000 Pathways), fuehrt aber zu Einschränkungen bei der Vollskalierung:

- Tiefe Graphtraversierungen (Tiefe > 3) erfordern mehrfache JOIN-Operationen, die schlecht skalieren.
- Keine native Unterstuetzung fuer Kuerzeste-Wege- oder Musterabgleich-Abfragen, die in Graphdatenbanken verfuegbar sind (z. B. Neo4j Cypher).
- Gleichzeitiger Schreibzugriff ist durch SQLites Dateisperrung auf Dateiebene limitiert.

Datenvollstaendigkeit

Nicht alle Pathways haben eine ausreichende Reactome-Abdeckung. Verwaiste Pathways, gewebespezifischer Metabolismus und kuerzlich charakterisierte Mechanismen sind moeglicherweise nicht repraesentiert. Die Gene-Ontology-Integration erhoeht die Breite, jedoch auf Kosten der Granularitaet – viele GO-Begriffe fuer biologische Prozesse sind zu generisch, um als aussagekraeftige funktionelle Pathways zu dienen.

EHR-Interoperabilitaet

Ein praktischer Einsatz ausschlussbasierter klinischer Entscheidungsunterstuetzung erfordert die Integration mit elektronischen Gesundheitsaktensystemen (EHR), um strukturierte Laborwerte des Patienten zu erhalten. Ohne interoperablen Zugang zu Echtzeit-Laborwerten ueber Standards wie HL7 FHIR bleibt das System auf manuell eingegebene Messwerte beschraenkt. EHR-Interoperabilitaet ist eine gut dokumentierte Herausforderung in der klinischen Informatik; ihre Loesung liegt ausserhalb des Rahmens dieses Konzeptpapiers, stellt aber eine kritische Anforderung fuer jede zukuenftige klinische Anwendung dar.

Messredundanz und Kontextualitaet

Die probabilistische Ausschlussformel (Definition 4) nimmt an, dass Labormessungen unabhaengige Evidenz ueber den Pathway-Status liefern. Jedoch warnt das Contextuality-by-Default-(CbD-)Framework von Dzhafarov und Kujala ([Dzhafarov and Kujala, 2016](#)), dass parallele Messungen informationelle Redundanz statt genuiner Unabhaengigkeit aufweisen koennen. Wenn zwei Laborwerte gleichzeitig abfallen, kann dies eine redundante Messung derselben Pathway-Ausgabe widerspiegeln, anstatt unabhaengige Evidenz fuer eine gemeinsame genetische Ursache (Pleiotropie) darzustellen. Eine rigorose Behandlung wuerde einen CbD-inspirierten Korrekturterm im Ausschlusswert erfordern, der die

Ueberlappung des Messkontexts beruecksichtigt. Diese Verfeinerung ist fuer zukuenftige Versionen des probabilistischen Modells geplant.

Verwandte Arbeiten

Phaenotypgesteuerte Diagnoseunterstuetzung

Phenomizer (Köhler et al., 2009) und PhenoTips (Girdea et al., 2013) repraesentieren den Stand der Technik in der phaenotypgesteuerten Diagnose. Beide Systeme gleichen Patientenphaenotypen (HPO-Terme) mit Krankheitsdatenbanken ab und ordnen Kandidatendiagnosen nach semantischer Aehnlichkeit. Sie sind effektiv beim Symptom-Krankheits-Abgleich, modellieren aber keine biologischen Pathways und nutzen die Pathway-Integritaet nicht fuer Ausschlusschliessen.

Pathway-Analyse in der Genomik

Gene Set Enrichment Analysis (GSEA) (Subramanian et al., 2005) und verwandte Werkzeuge identifizieren dysregulierte Pathways aus Expressionsdaten. Diese Methoden arbeiten auf Populationsebene und erfordern Omics-Daten, die in der klinischen Routineversorgung typischerweise nicht verfuegbar sind. Das vorgeschlagene System arbeitet mit individuellen Laborwerten des Patienten und ist daher in klinischen Standardarbeitsablaeufen anwendbar.

Graphbasiertes klinisches Schliessen

Wissensgraphen fuer die klinische Entscheidungsunterstuetzung wurden in verschiedenen Kontexten untersucht. Klinische Wissensgraphen aus elektronischen Gesundheitsakten (Rotmensch et al., 2017) erfassen statistische Assoziationen zwischen Diagnosen, Laborwerten und Behandlungen. Grossskalige biomedizinische Wissensgraphen wie Hetionet (Himmelstein et al., 2017) integrieren diverse Datenquellen fuer Drug-Repurposing und Hypothesengenerierung. Keines dieser Systeme nutzt jedoch den Pathway-Status als erst-rangige Einschraenkung im Ausschlusschliessen.

LLM-gestuetztes biomedizinisches Schliessen

Neuere Arbeiten kombinieren grosse Sprachmodelle mit biomedizinischen Wissensgraphen. ESCARGOT (Matsumoto et al., 2025) integriert LLMs mit einer dynamischen „Graph of Thoughts“-Architektur und biomedizinischen Wissensgraphen fuer Multihop-Schlussfolgerungsaufgaben. Waehrend ESCARGOT effektives graphbasiertes Schliessen in biomedizinischen Kontexten demonstriert, arbeitet es als Allzweck-Schlussfolgerungsagent ohne explizite Ausschlusslogik. Das vorgeschlagene System teilt die Betonung des wissensgraphgesteuerten Schliessens, unterscheidet sich aber grundlegend in seinem Ordnungsprinzip: funktionelle Pathways als erst-rangige diagnostische Einschraenkungen statt allgemeiner Graphtraversierung.

HealthGenie (Gao et al., 2025) demonstriert wissensgetriebene LLM-Integration fuer personalisierte Gesundheitsberatung. Sein Ansatz organisiert Wissensgraphen um Benutzerprofile und Ernaehrungsempfehlungen – eine symptomzentrierte (oder bedarfszentrierte) Organisation. Im Gegensatz dazu organisiert das vorgeschlagene System um biologi-

sche funktionelle Pathways, was mechanistisches Ausschlusschliessen ermoeeglicht, das in symptomzentrierten Architekturen nicht verfuegbar ist.

Vergleichszusammenfassung

Tabelle 10: Vergleich des vorgeschlagenen Systems mit verwandten Ansaetzen.

System	Primaere Entitaet	Ausschluss	Laborwerte	Pathways
Phenomizer	HPO-Phaenotypen	Nein	Nein	Nein
PhenoTips	Patientenphaenotypen	Nein	Begrenzt	Nein
GSEA/KEGG	Pathways	Nein	Nur Omics	Ja
Hetionet	Heterogen	Nein	Nein	Teilweise
Klinische KGs	EHR-Daten	Nein	Ja	Nein
ESCARGOT	KG + LLM	Nein	Nein	Teilweise
HealthGenie	KG + LLM	Nein	Nein	Nein
Vorgeschlagen	Pathways	Ja	Ja	Ja

Evaluationsframework

Benchmark-Datensatz

Eine rigorose Validierung erfordert einen kuratierten Benchmark von 20–50 bestaetigten genetischen Diagnosen, bei denen:

1. Laborprofile des Patienten zum Zeitpunkt der Erstvorstellung (vor der genetischen Diagnose) vorliegen.
2. Die genetische Diagnose bestaetigt ist (Variante + Phaenotyp + funktionelle Studie).
3. Der Pathway-Status des Patienten retrospektiv aus Labordaten rekonstruiert werden kann.

Zielquellen umfassen Register fuer seltene Erkrankungen (EURORDIS), klinische Synopsen aus OMIM und publizierte Fallserien mit umfassenden Laboruntersuchungen.

Primaere Metrik

Die Kandidatenreduktionsrate (CRR, Gleichung 5) dient als primaeres Erfolgskriterium. Ein $CRR > 0,30$ unterstuetzt die Kernhypothese; ein $CRR < 0,10$ wuerde auf unzureichenden diagnostischen Mehrwert hinweisen.

Sicherheitseinschraenkung: Das bestaetigte ursaechliche Gen darf *niemals* ausgeschlossen werden (Falschausschlussrate = 0). Jeder Falschausschluss im Benchmark invalidiert das Modell fuer die klinische Anwendung.

Alternative Validierung: Synthetische Patientenpersonas

Ein alternativer Validierungsweg adressiert den Mangel an annotierten realen Datensätzen für seltene Erkrankungen. LLM-generierte synthetische Patientenpersonas können durch gezielte Störungen im Pathway-Graphen konstruiert werden – beispielsweise durch Simulation eines ANK1-Defekts, indem der Erythrozytenmembranintegritäts-Pathway auf „gestört“ gesetzt wird und konsistente Laborwerte abgeleitet werden. Da das ursächliche Gen *a priori* definiert ist, kann die Ausschluss-Engine mit exakter Grundwahrheit evaluiert werden: Das System muss nicht-ursächliche Gene ausschliessen (Messung der CRR) und darf das eingepflanzte ursächliche Gen niemals ausschliessen (Messung der Falschausschlussrate). Dieser Ansatz ergänzt den Realfall-Benchmark und ermöglicht systematisches Testen über ein breiteres Spektrum von Krankheitsszenarien, als möglicherweise aus Registern allein verfügbar ist.

Sekundäre Metriken

- **Rangverbesserung:** Position des korrekten Gens in der Rangkandidatenliste nach Ausschlussfilterung.
- **Abdeckung:** Prozentsatz der Benchmark-Fälle, bei denen mindestens ein Pathway anhand verfügbarer Labordaten bewertet werden kann.
- **Vergleich:** CRR gegenüber standardmäßiger HPO-only-Filterung auf dem gleichen Fallsatz.

Diskussion

Der pathway-zentrierte Ansatz adressiert eine strukturelle Lücke in der aktuellen klinischen Entscheidungsunterstützung: die systematische Nutzung *negativer Evidenz* (was nachweislich funktioniert), um den diagnostischen Raum einzuschränken. Dies ist konzeptionell analog zur industriellen Fehlerdiagnose, bei der funktionierende Subsysteme ganze Äste des Fehlerbaums eliminieren.

Mehrere Designentscheidungen verdienen Diskussion:

Warum Pathways als Zentrum, nicht Gene oder Diagnosen? Gene sind Ursachen; Diagnosen sind Folgen. Keines von beiden bietet die mechanistische Zwischenschicht, die für Ausschlussentscheidungen benötigt wird. Pathways repräsentieren die funktionellen Einheiten, die genetische Ursachen mit klinischen Auswirkungen verbinden, und sind damit der natürliche Drehpunkt für sowohl Einschluss- als auch Ausschlusslogik.

Binaerer vs. probabilistischer Ausschluss. Das binaere Modell ist konzeptionell einfacher und leichter zu validieren (ein Gen ist entweder ausgeschlossen oder nicht), kann aber keine Unsicherheit ausdrücken. Das probabilistische Modell erfasst abgestufte Evidenz, erfordert jedoch kalibrierte Parameter. Wir empfehlen das binaere Modell für die initiale Validierung und das probabilistische Modell für die klinische Erkundung.

Skalierbarkeit. Der aktuelle Prototyp bewaeltigt das Demonstrationsszenario (~ 50 Knoten, ~ 80 Kanten) ohne Leistungsprobleme. Die Skalierung auf die vollstaendige Reactome-Datenbank (> 2400 Pathways, $> 10\,000$ Reaktionen) wird Leistungstests und wahrscheinlich eine Migration zu einer Graphdatenbank-Backend erfordern.

Fazit und zukuenftige Arbeiten

Der funktionale pathway-zentrierte Wissensgraph repraesentiert einen strukturell eigenstaendigen Ansatz zur Differentialdiagnose-Unterstuetzung, der Pathway-Status-Evidenz als explizite diagnostische Einschränkungen nutzt. Die prototypische Implementierung demonstriert die Machbarkeit ueber alle Kernkomponenten hinweg: Datenaufnahme aus sechs oeffentlichen Datenbanken, Graphmodellierung mit semantischen Kantentypen, binäres und probabilistisches Ausschlusschliessen, Mustererkennung und interaktive Visualisierung.

Die Kernhypothese – dass Pathway-Ausschluss den Kandidatengenraum um $\geq 30\%$ ohne Falschausschluesse reduziert – ist testbar und stellt das primaere empirische Ziel fuer zukuenftige Arbeiten dar.

Zentrale offene Aufgaben

1. **Benchmark-Datensatz:** Kuratierung von 20–50 Faellen aus Registern fuer seltene Erkrankungen mit Laborprofilen und bestaetigten genetischen Diagnosen.
2. **Gewichtskalibrierung:** Entwicklung einer datengetriebenen Methode zur Schaetzung der Pathway-Konfidenzgewichte $c(p_i)$ aus Messzuverlaessigkeit und Pathway-Redundanz.
3. **OMIM/HPO-Integration:** Verknuepfung von Krankheit-Gen-Assoziationen aus OMIM und HPO-Annotationen, um einen direkten Vergleich mit rein phänotyp-basierter Filterung zu ermoeglichen.
4. **Graphdatenbank-Migration:** Evaluation von Neo4j oder aehnlichen Backends fuer Skalierbarkeit ueber den SQLite-Prototyp hinaus.
5. **Vergleich mit klinischen Werkzeugen:** Benchmark gegen Phenomizer auf demselben Fallsatz zur Quantifizierung des Mehrwerts pathway-zentrierten Ausschlusses.
6. **Temporale Modellierung:** Erweiterung des Frameworks zur Erfassung der Krankheitsprogression und zeitabhaengiger Pathway-Statusaenderungen.

Daten- und Softwareverfuegbarkeit

Der Quellcode des Prototyps, einschliesslich Datenbankschema, Aufnahmepipelines, Ausschluss-Engines und GUI-Anwendung, ist als Open-Source-Software verfuegbar. Das System integriert ausschliesslich oeffentliche Datenquellen; es werden keine Patientendaten verwendet oder benoetigt.

KI-Offenlegung

Bei der Erstellung dieses Manuskripts wurden KI-gestuetzte Werkzeuge (Claude, Anthropic) eingesetzt, insbesondere fuer Literaturrecherche, Unterstuetzung bei der Codeentwicklung, Textstrukturierung und Uebersetzungshilfe. Der konzeptuelle Entwurf, die wissenschaftliche Argumentation, die formale Modellentwicklung und die Verantwortung fuer alle Inhalte liegen ausschliesslich beim Autor.