

Funktionaler Pathway-zentrierter medizinischer Wissensgraph mit Ausschlusslogik

Eine systemmedizinische Architektur zur Unterstützung der
Differentialdiagnose

Lukas Geiger

Unabhängiger Forscher, Bernau, Deutschland

ORCID: <https://orcid.org/0009-0005-7296-1534>

Juni 2026

Zusammenfassung

Wir stellen den Entwurf und die prototypische Implementierung eines funktionalen Pathway-zentrierten medizinischen Wissensgraphen für die Differentialdiagnoseforschung vor. Herkömmliche klinische Entscheidungsunterstützungssysteme organisieren Wissen um Diagnosen, Symptome oder Gene als primäre Entitäten. Im Gegensatz dazu verwendet das vorgeschlagene System *biologische funktionelle Pathways* als zentrales Ordnungsprinzip, wobei Gene, Proteine, Laborwerte, anatomische Lokalisationen, Zelltypen und klinische Diagnosen als sekundäre Annotationen verknüpft werden.

Diese Architektur unterstützt eine spezifische Form des *ausschlussbasierten Schließens*: Wenn ein funktioneller Pathway auf Basis von Laborwerten als hinreichend intakt gilt, können Gene, die für diesen Pathway erforderlich sind, als primäre Krankheitsursachen beim aktuellen Patienten zurückgestuft werden, vorbehaltlich von Redundanz, Pleiotropie und Einschränkungen der Messqualität. Das System ist als SQLite-gestützter Prototyp mit einer grafischen PySide6-Oberfläche implementiert und integriert öffentliche Datenquellen (Reactome, Gene Ontology, UniProt, HGNC, Uberon, Cell Ontology).

Wir beschreiben das formale Ausschlussmodell in binärer und probabilistischer Variante, seine Annahmen und Einschränkungen und schlagen einen Validierungsrahmen vor. Der Prototyp wird an einem Hämolyse-Immundefizienz-Szenario demonstriert, das fünf funktionelle Pathways, elf Gene und sieben Labormarker umfasst. Das System ist als Forschungswerkzeug zur Erkundung einer Pathway-zentrierten Ausschlusslogik positioniert, nicht als validiertes klinisches Entscheidungsunterstützungssystem.

Schlüsselwörter: Wissensgraph, Differentialdiagnose, funktionelle Pathways, Ausschlusslogik, Systemmedizin, Reactome, Gene Ontology

1 Einleitung und Motivation

Die Differentialdiagnose bei komplexen Multisystemerkrankungen scheitert häufig nicht am Mangel an Daten, sondern an der Unfähigkeit, heterogene Evidenz systematisch zu integrieren. Ein Patient mit abnormalen Laborwerten kann Hunderte genetischer Kandidatenursachen haben; aktuelle klinische Werkzeuge präsentieren diese größtenteils als Ranglisten, ohne die logische Struktur *ausgeschlossener* Möglichkeiten auszunutzen.

Die zentrale Beobachtung, die diese Arbeit motiviert, lautet:

Wenn ein biologischer funktioneller Pathway durch die vorliegenden Daten hinreichend als intakt gestützt ist, dann können Gene, deren pathogene Wirkung diesen Pathway voraussichtlich stören würde, als primäre Ursachen einer Funktionsstörung zurückgestuft werden.

Dies transformiert positive Evidenz (offenbar intakte Pathway-Funktion) in negative diagnostische Einschränkungen (geringer priorisierte Kandidatengene) und kann so den Kandidatenraum verkleinern, bevor eine detailliertere differentialdiagnostische Prüfung erfolgt.

Bestehende Systeme organisieren Wissen unterschiedlich. PhenoTips ([Girdea et al., 2013](#)) und Phenomizer ([Köhler et al., 2009](#)) gleichen Patientenphänotypen über die Human Phenotype Ontology ([Robinson et al., 2008](#)) mit Krankheitsdatenbanken ab. Diese Systeme sind hervorragend im Symptom-Krankheits-Abgleich, nutzen aber nicht die Pathway-Integrität als Ausschlussevidenz. Pathway-Datenbanken wie Reactome ([Fabregat et al., 2018](#)) und KEGG ([Kanehisa et al., 2023](#)) organisieren sich um biochemische Reaktionen, sind aber nicht für ausschlussbasiertes klinisches Schließen konzipiert. Gene Ontology ([Ashburner et al., 2000](#)) liefert feingranulare Prozessbeschreibungen, es fehlt jedoch der klinische Entscheidungsrahmen.

Das vorgeschlagene System schließt diese Lücke, indem es funktionelle Pathways als *primäre Entitäten* in einem Wissensgraphen behandelt, wobei alle anderen biomedizinischen Konzepte – Gene, anatomische Lokalisationen, Zelltypen, Labormarker und Diagnosen – als sekundäre Annotationen angebunden werden. Diese strukturelle Entscheidung macht das Schließen über den Pathway-Status explizit und rechnerisch handhabbar, ohne die biologisch interpretierbare Zwischenschicht zu verlieren.

1.1 Beiträge

1. Ein **Datenmodell**, das funktionelle Pathways als zentrales Ordnungsprinzip für klinisches Schließen verwendet und sechs Entitätstypen über semantisch typisierte Kanten verknüpft.
2. Ein **formaler Ausschlussrahmen** mit sowohl binärer als auch probabilistischer Variante, der die systematische Priorisierung und Zurückstufung von Kandidatengen auf Basis von Pathway-Integritätsevidenz ermöglicht.
3. Eine **prototypische Implementierung** mit Datenaufnahme aus sechs öffentlichen biologischen Datenbanken, einem interaktiven Graphen-Explorer und einer Diagnoseabfrage-Engine.
4. Ein **Validierungsrahmen**, der Metriken, Benchmark-Anforderungen und Vergleichskriterien zur Bewertung des Ansatzes spezifiziert.

2 Problemstellung und formale Hypothese

2.1 Formale Problemstellung

Sei $\mathcal{P} = \{p_1, \dots, p_n\}$ die Menge der biologischen funktionellen Pathways für einen gegebenen Patientenkontext. Sei $\mathcal{G}$ die Menge der Kandidatengene. Sei $\mathcal{E}(p_i) \subseteq \mathcal{G}$ die Menge der für Pathway p_i *essentiellen* Gene. Sei $s(p_i) \in \{0, 1\}$ der beobachtete Pathway-Status: 1 = intakt, 0 = gestört oder unbekannt.

Definition 1 (Binäre Ausschlussregel). *Wenn $s(p_i) = 1$, dann gilt $\forall g \in \mathcal{E}(p_i)$: Gen g ist im aktuellen Kandidatenset für primäre Krankheitsursachen als ausgeschlossen markiert, sofern g nur in Pathways essentiell ist, die alle intakt sind:*

$$\text{excluded}(g) \iff \forall p_i \text{ s.t. } g \in \mathcal{E}(p_i) : s(p_i) = 1 \quad (1)$$

Definition 2 (Probabilistischer Ausschlusswert). *Für ein Gen g ist die Ausschlusskonfidenz:*

$$\text{excl}(g) = \prod_{i: g \in \mathcal{E}(p_i)} c(p_i) \cdot b(g) \quad (2)$$

wobei $c(p_i) \in [0, 1]$ die Pathway-Statuskonfidenz ist (intakt: 0,95, unbekannt: 0,50, gestört: 0,05) und $b(g) \in [0, 1]$ ein Multi-Pathway-Bonusfaktor:

$$b(g) = \min\left(1.0, 0.7 + 0.1 \cdot |\{p_i : g \in \mathcal{E}(p_i) \wedge s(p_i) = 1\}|\right) \quad (3)$$

Der Verdachtswert berücksichtigt die Genredundanz:

$$\text{susp}(g) = (1 - \text{excl}(g)) \cdot r(g) \quad (4)$$

wobei $r(g) \in \{1.0, 0.85, 0.6, 0.3\}$ den Redundanzgrad des Gens abbildet (keine, gering, mittel, hoch).

2.2 Kernhypothese

Pathway-statusbasierte Ausschlusslogik reduziert die Kandidatengenmenge bei komplexen seltenen Erkrankungen systematisch um mindestens 30 % gegenüber rein phänotypbasierter Filterung, wenn sie auf einem kuratierten Benchmark-Datensatz evaluiert wird.

Dies ist eine spezifische, falsifizierbare Hypothese. Die 30 %-Schwelle ist als minimale klinisch bedeutsame Reduktion gesetzt; ein Nullergebnis ($< 10\%$ Reduktion) würde darauf hinweisen, dass die Ausschlusslogik über bestehende Werkzeuge hinaus wenig diagnostischen Mehrwert bietet.

Die Kandidatenreduktionsrate (CRR) ist definiert als:

$$\text{CRR} = 1 - \frac{|\mathcal{G}_{\text{after exclusion}}|}{|\mathcal{G}_{\text{before exclusion}}|} \quad (5)$$

3 Systemarchitektur

3.1 Datenmodell

Die zentrale Entität ist der **FunctionalPathway**-Knoten, der einen diskreten biologischen Prozess mit beobachtbaren Ein- und Ausgaben repräsentiert. Abbildung 1 zeigt das vollständige Datenmodell.




Abbildung 1: Entity-Relationship-Diagramm des Pathway-zentrierten Wissensgraphen. Durchgezogene Pfeile zeigen primäre Beziehungen über den Pathway-Hub; gestrichelte Pfeile zeigen sekundäre Querverbindungen.

Jeder Entitätstyp trägt domänenspezifische Attribute:

- **FunctionalPathway**: Name, Beschreibung, primäre Ausgabe, Zeitklasse (akut oder chronisch), Status (intakt, gestört oder unbekannt) und externe ID (Reactome/GO).
- **BodyLocation** (Uberon): Organ, Subkompartiment, Zirkulationstyp, Immunrolle.
- **CellType** (Cell Ontology): Linie, Reifungsstadium, Lebensdauer, Mobilität.
- **Gene/Protein** (HGNC/UniProt): Symbol, Funktionstyp (strukturell, regulatorisch, signalgebend, metabolisch), Redundanzgrad, Expressionsorte.
- **MeasurementType**: Name, LOINC-Code, Referenzbereich, Messort, Sensitivität, Spezifität.
- **ClinicalDiagnosis**: Name, ICD-10-Code, Beschreibung.

Kantentypen tragen semantische Bezeichnungen (Tabelle 1) und bei Gen-Pathway-Kanten ein `is_essential`-Flag, das modulatorische von essentiellen Genbeiträgen unterscheidet.

Tabelle 1: Semantische Kantentypen im Wissensgraphen.

Quelle	Ziel	Relation
Pathway	BodyLocation	OCCURS_IN
Pathway	CellType	EXECUTED_BY
Gene	Pathway	REQUIRES (essentiell) / MODULATES
Measurement	Pathway	MONITORS_OUTPUT_OF
Measurement	BodyLocation	REPRESENTS_ACTIVITY_IN
Pathway	Diagnosis	DISRUPTION_LEADS_TO
Gene	BodyLocation	EXPRESSED_IN

3.2 Implementierung

Der Prototyp verwendet **SQLite** als Backend, wobei relationale Tabellen eine Graphstruktur über Assoziationstabellen simulieren (Abbildung 2). Das System umfasst vier Hauptmodule:

1. **Importmodul:** Lädt sechs öffentliche Datenquellen herunter und parst sie (Abschnitt 3.3), mit einem manifestbasierten Tracking-System zur Vermeidung redundanter Downloads.
2. **Engine-Modul:** Implementiert die Ausschlusslogik (binär und probabilistisch), Graphtraversierungsabfragen, Mustererkennung für Messwert-Signaturen und die Erzeugung menschenlesbarer Erklärungen.
3. **GUI-Modul:** Eine PySide6-basierte Desktop-Anwendung mit vier Tabs: Graph Explorer (interaktive Netzwerkvisualisierung über NetworkX), Ausschluss-Panel (Pathway-Statusverwaltung und -analyse), Diagnoseabfrage (messwertgesteuerte Hypothesengenerierung) und Datenbrowser (Inspektion von Rohdaten-Tabellen).
4. **Datenbankmodul:** Schemadefinition, CRUD-Hilfsfunktionen und Kantenverknüpfungsfunktionen mit Fremdschlüsselconstraints.




Abbildung 2: Relationales SQLite-Schema. Graue Kästen sind Entitätstabellen; blaue Kästen sind Assoziations-(Kanten-)Tabellen mit Fremdschlüsseln.

Ein dedizierter **Graph Explorer** (NetworkX-basiert) visualisiert Teilgraphen mit bei Bedarf nachgeladenen Nachbarschaften. Das Graph-Layout wird in einem Hintergrund-Thread berechnet, um die GUI-Responsivität zu erhalten. Knoten sind nach Entitätstyp farbcodiert; Pathway-Knoten zeigen zusätzlich ihren Status (intakt/gestört/unbekannt) durch Randfarben an.

Hinweis zur Wahl der Graphdatenbank. Die aktuelle SQLite-Implementierung ermöglicht schnelles Prototyping, führt aber zu bekannten Einschränkungen bei tiefer Graphtraversierung (siehe Abschnitt 6). Ein Produktivsystem würde von Neo4j oder einer vergleichbaren nativen Graphdatenbank profitieren. Der Prototyp demonstriert das konzeptuelle Modell; Leistungsvergleiche mit graphnativen Backends sind geplant.

3.3 Datenquellen

Das System integriert sechs öffentliche biologische Datenbanken, die jeweils einen spezifischen Entitätstyp zum Wissensgraphen beitragen:

Tabelle 2: Integrierte Datenquellen und ihre Rollen.

Quelle	Entitätstyp	Format	Status
Reactome (Fabregat et al., 2018)	Pathways, Reaktionen	TSV	Integriert
Gene Ontology (Ashburner et al., 2000)	Biologische Prozesse	OBO, GAF	Integriert
UniProt (The UniProt Consortium, 2023)	Proteine, Gen-Links	TSV	Integriert
HGNC (Braschi et al., 2019)	Gennomenklatur	TSV	Integriert
Uberon (Mungall et al., 2012)	Anatomische Lokalisationen	OBO	Integriert
Cell Ontology (Diehl et al., 2016)	Zelltypen	OBO	Integriert
KEGG (Kanehisa et al., 2023)	Pathway-Karten	REST API	Geplant
OMIM (Amberger et al., 2019) / HPO (Robinson et al., 2008)	Krankheits-Gen-Links	—	Geplant

Die Datenaufnahme folgt einer definierten Reihenfolge (HGNC → Uberon → Cell Ontology → UniProt → Reactome → GO), um Fremdschlüsselabhängigkeiten zu erfüllen. Jede Quelle wird über eine Manifestdatei verfolgt, die Download-Zeitstempel, SHA-256-Prüfsummen und Importstatus aufzeichnet.

4 Ausschlusslogik

4.1 Binärer Ausschluss

Die binäre Ausschluss-Engine (Definition 1) iteriert über alle Gene, die in mindestens einem Pathway als essentiell markiert sind. Für jedes Gen werden alle Pathways abgerufen, in denen das Gen essentiell ist, und es wird geprüft, ob *alle* dieser Pathways den Status „intakt“ haben. Ist dies der Fall, wird das Gen ausgeschlossen; andernfalls bleibt es ein Kandidat.

Algorithm 1 Binäre Ausschlussanalyse

Require: Menge von Pathways $\mathcal{P}$ mit Status $s(p_i)$, essentielle Gen-Zuordnung $\mathcal{E}$

Ensure: Mengen $\mathcal{G}_{\text{excluded}}$, $\mathcal{G}_{\text{candidate}}$

```
1:  $\mathcal{I} \leftarrow \{p_i \in \mathcal{P} : s(p_i) = \text{intakt}\}$ 
2: for all  $g \in \bigcup_{p \in \mathcal{P}} \mathcal{E}(p)$  do ▷ Alle essentiellen Gene
3:    $P_g \leftarrow \{p \in \mathcal{P} : g \in \mathcal{E}(p)\}$  ▷ Pathways, die  $g$  benötigen
4:   if  $P_g \subseteq \mathcal{I}$  und  $P_g \neq \emptyset$  then
5:      $\mathcal{G}_{\text{excluded}} \leftarrow \mathcal{G}_{\text{excluded}} \cup \{g\}$ 
6:   else
7:      $\mathcal{G}_{\text{candidate}} \leftarrow \mathcal{G}_{\text{candidate}} \cup \{g\}$ 
8:   end if
9: end for
```

Die Konfidenz des Ausschlusses hängt von der Anzahl intakter Pathways ab: Ein Gen, das über mehrere unabhängige intakte Pathways ausgeschlossen wird, hat stärkere Evidenz als eines, das über einen einzelnen Pathway ausgeschlossen wird.

4.2 Probabilistischer Ausschluss

Die probabilistische Engine (Definition 2) erweitert das binäre Modell durch Zuweisung kontinuierlicher Konfidenzwerte. Drei Faktoren tragen bei:

1. **Pathway-Evidenz:** Jeder Pathway-Status wird auf einen Konfidenzwert abgebildet (intakt: 0,95, unbekannt: 0,50, gestört: 0,05). Die kombinierte Pathway-Konfidenz für ein Gen ist das Produkt über alle seine essentiellen Pathways.
2. **Multi-Pathway-Bonus:** Gene, die in mehreren intakten Pathways essentiell sind, erhalten einen Bonusfaktor, der die stärkere Evidenz aus unabhängigen Quellen widerspiegelt.
3. **Redundanzgewichtung:** Der Verdachtswert wird durch den Redundanzgrad des Gens moduliert. Gene ohne funktionelle Absicherung (Redundanz = „keine“) erhalten volles Verdachtsgewicht ($r = 1,0$); hoch redundante Gene erhalten reduziertes Gewicht ($r = 0,3$).

Gene werden nach Ausschlusskonfidenz kategorisiert: hoch ($\geq 0,8$), moderat (0,3–0,8) oder verdächtig ($< 0,3$). Diese dreiteilige Klassifikation soll eine priorisierte fachliche Prüfung unterstützen, statt automatisch eine klinische Entscheidung zu erzeugen.

4.3 Mustererkennung

Zusätzlich zur Ausschlusslogik implementiert das System eine **Signaturerkennung für Messwerte**. Eine Signatur ist ein vordefiniertes Muster abnormaler Laborwerte (z. B. „Hämolyse-Signatur“: niedriges Haptoglobin + hohes LDH + hohes indirektes Bilirubin + hohe Retikulozyten + niedriges Hämoglobin). Jede Komponente trägt ein Gewicht, das ihre diagnostische Bedeutung widerspiegelt.

Bei einer Menge abnormaler Messwerte berechnet das System einen gewichteten Übereinstimmungswert gegen alle definierten Signaturen:

$$\text{match}(S) = \frac{\sum_{c \in S_{\text{matched}}} w_c}{\sum_{c \in S_{\text{all}}} w_c} \quad (6)$$

Signaturen mit $\text{match} \geq 0,3$ werden gemeldet, was eine schnelle Identifikation bekannter klinischer Muster ermöglicht.

5 Hämolysen und Immundefizienz als Demonstration

Der Prototyp enthält einen kuratierten Seed-Datensatz, der die Überschneidung von hereditärer Sphärozytose, autoimmunhämolytischer Anämie und Agammaglobulinämie modelliert. Dieses Szenario wurde gewählt, weil es mehrere interagierende Pathways mit gemeinsamen anatomischen Lokalisationen (Milz, Knochenmark) umfasst und die Ausschlusslogik über unabhängige funktionelle Domänen hinweg demonstriert.

5.1 Funktionelle Pathways

Fünf Pathways werden modelliert (Tabelle 3), die zwei klinische Domänen (Hämatologie und Immunologie) mit unterschiedlichen zeitlichen Charakteristiken umfassen.

Tabelle 3: Funktionelle Pathways im Demonstrationsszenario.

Pathway	Ausgabe	Zeitlich
Erythrozytenmembran-Integrität	Stabile bikonkave Erythrozyten	Chronisch
Erythrozytenabbau (Hämolysen)	Freies Hb $\rightarrow$ Bilirubin	Akut
Milzfiltration	Entfernung defekter Zellen	Akut
Frühe B-Zell-Differenzierung	Funktionelle Prä-B-Zellen	Chronisch
Antikörperproduktion	IgG, IgM, IgA	Beides

5.2 Gen-Pathway-Essentialität

Elf Gene sind mit diesen Pathways verknüpft, mit expliziten Essentialitätsannotationen (Tabelle 4). Das Essentialitätsflag ist das entscheidende Attribut, das die Ausschlusslogik ermöglicht: Nur essentielle Gene können ausgeschlossen werden, wenn ihr Pathway intakt ist.

Tabelle 4: Gene und ihre Pathway-Essentialität im Demonstrationsszenario.

Gen	Pathway	Essentiell	Redundanz
ANK1	Membranintegrität	Ja	Keine
SLC4A1	Membranintegrität	Ja	Keine
SPTA1	Membranintegrität	Ja	Gering
SPTB	Membranintegrität	Ja	Keine
EPB42	Membranintegrität	Ja	Gering
HMOX1	Hämolysen	Ja	Gering
HP	Hämolysen	Nein	Gering
BLNK	B-Zell-Differenzierung	Ja	Keine
CD19	B-Zell-Differenzierung	Ja	Keine
PAX5	B-Zell-Differenzierung	Ja	Keine
NOTCH2	Milzfiltration, B-Zell-Diff.	Ja / Nein	Gering

5.3 Ausschlusszenario

Betrachten wir einen Patienten mit folgenden Befunden:

- Niedriges Hämoglobin (Anämie)
- Niedriges Haptoglobin (Hämolyse-Marker)
- Hohes LDH, hohes indirektes Bilirubin (Hämolyse)
- Normale B-Zell-Zahl (CD19+)
- Normale IgG-Spiegel

Das System leitet ab:

1. Normale B-Zell-Zahl $\Rightarrow$ B-Zell-Differenzierungs-Pathway *intakt* $\Rightarrow$ **Ausschluss** von BLNK, CD19, PAX5.
2. Normales IgG $\Rightarrow$ Antikörperproduktions-Pathway *intakt*.
3. Hämolyse-Marker abnormal $\Rightarrow$ Hämolyse-Pathway *gestört*.
4. NOTCH2 ist essentiell in der Milzfiltration (Status unbekannt) und nicht-essentiell in der B-Zell-Differenzierung $\Rightarrow$ **bleibt Kandidat**.
5. Die Membrangene ANK1, SLC4A1, SPTA1, SPTB und EPB42 sind nur im Membran-Pathway essentiell. Bei unbekanntem oder gestörtem Status $\Rightarrow$ **bleiben Kandidaten**.

Ergebnis: 3 von 10 essentiellen Genen werden zurückgestuft (CRR = 30 %), was in diesem Demonstrationsfall der Hypothesenschwelle entspricht. Die verbleibenden Kandidaten umfassen die membranstrukturellen Gene, die mit hereditärer Sphärozytose assoziiert sind.

6 Annahmen und Einschränkungen

6.1 Unabhängigkeitsannahme

Das binäre Ausschlussmodell nimmt an, dass Pathways *funktionell unabhängig* sind: Ein intakter Pathway p_i schließt seine essentiellen Gene unabhängig vom Status anderer Pathways aus. Diese Annahme ist **bekanntermaßen falsch** in vielen biologischen Kontexten:

- Viele Gene sind in mehreren Pathways beteiligt (*Pleiotropie*). Ein über Pathway p_i ausgeschlossenes Gen könnte dennoch über einen anderen Pathway p_j , der nicht erfasst wird, ursächlich sein. Das Modell adressiert dies, indem es verlangt, dass *alle* Pathways eines Gens intakt sein müssen, bevor ein Ausschluss erfolgt.
- Kompensationsmechanismen können die gemessenen Pathway-Ausgaben aufrechterhalten, selbst wenn ein essentielles Gen teilweise dysfunktional ist.
- Der binäre Status $s(p_i) \in \{0, 1\}$ ist eine Vereinfachung; die reale Pathway-Aktivität existiert auf einem Kontinuum.

Das probabilistische Modell mildert diese Einschränkungen teilweise durch kontinuierliche Konfidenzwerte, aber die Gewichtsparameter werden derzeit heuristisch zugewiesen.

6.2 Definition der Essentialität

„Essentielles Gen“ ist operationell definiert als ein Gen, das in Reactome oder kuratierten Quellen als *erforderlich* für mindestens eine Reaktion im Pathway annotiert ist. Diese Definition ist konservativ und sollte unter Verwendung kuratierter Essentialitätsdatenbanken (z. B. DepMap, CRISPR-Essentialitätsscreens) verfeinert werden.

6.3 Datenbank-Backend

Die SQLite-Implementierung genügt für den aktuellen Prototyp (~17 MB Datenbank, <2000 Pathways), führt aber zu Einschränkungen bei der Vollskalierung:

- Tiefe Graphtraversierungen (Tiefe > 3) erfordern mehrfache JOIN-Operationen, die schlecht skalieren.
- Keine native Unterstützung für Kürzeste-Wege- oder Musterabgleich-Abfragen, die in Graphdatenbanken verfügbar sind (z. B. Neo4j Cypher).
- Gleichzeitiger Schreibzugriff ist durch SQLites Dateisperrung auf Dateiebene limitiert.

6.4 Datenvollständigkeit

Nicht alle Pathways haben eine ausreichende Reactome-Abdeckung. Verwaiste Pathways, gewebespezifischer Metabolismus und kürzlich charakterisierte Mechanismen sind möglicherweise nicht repräsentiert. Die Gene-Ontology-Integration erhöht die Breite, jedoch auf Kosten der Granularität – viele GO-Begriffe für biologische Prozesse sind zu generisch, um als aussagekräftige funktionelle Pathways zu dienen.

6.5 EHR-Interoperabilität

Ein praktischer Einsatz ausschlussbasierter klinischer Entscheidungsunterstützung erfordert die Integration mit elektronischen Gesundheitsaktensystemen (EHR), um strukturierte Laborwerte des Patienten zu erhalten. Ohne interoperablen Zugang zu Echtzeit-Laborwerten über Standards wie HL7 FHIR ([HL7 International, 2023](#)) bleibt das System auf manuell eingegebene Messwerte beschränkt. EHR-Interoperabilität ist eine gut dokumentierte Herausforderung in der klinischen Informatik; ihre Lösung liegt außerhalb des Rahmens dieses Konzeptpapiers, stellt aber eine kritische Anforderung für jede zukünftige klinische Anwendung dar.

6.6 Messredundanz und Kontextualität

Die probabilistische Ausschlussformel (Definition 2) nimmt an, dass Labormessungen unabhängige Evidenz über den Pathway-Status liefern. Jedoch warnt das Contextuality-by-Default-(CbD-)Framework von Dzhafarov und Kujala ([Dzhafarov and Kujala, 2016](#)), dass parallele Messungen informationelle Redundanz statt genuiner Unabhängigkeit aufweisen können. Wenn zwei Laborwerte gleichzeitig abfallen, kann dies eine redundante Messung derselben Pathway-Ausgabe widerspiegeln, anstatt unabhängige Evidenz für eine gemeinsame genetische Ursache (Pleiotropie) darzustellen. Eine rigorose Behandlung

würde einen CbD-inspirierten Korrekturterm im Ausschlusswert erfordern, der die Überlappung des Messkontexts berücksichtigt. Diese Verfeinerung ist für zukünftige Versionen des probabilistischen Modells geplant.

7 Verwandte Arbeiten

7.1 Phänotypgesteuerte Diagnoseunterstützung

Phenomizer (Köhler et al., 2009) und PhenoTips (Girdea et al., 2013) repräsentieren den Stand der Technik in der phänotypgesteuerten Diagnose. Beide Systeme gleichen Patientenphänotypen (HPO-Terme) mit Krankheitsdatenbanken ab und ordnen Kandidatendiagnosen nach semantischer Ähnlichkeit. Sie sind effektiv beim Symptom-Krankheits-Abgleich, modellieren aber keine biologischen Pathways und nutzen die Pathway-Integrität nicht für ausschlussbasiertes Schließen.

7.2 Pathway-Analyse in der Genomik

Gene Set Enrichment Analysis (GSEA) (Subramanian et al., 2005) und verwandte Werkzeuge identifizieren dysregulierte Pathways aus Expressionsdaten. Diese Methoden arbeiten auf Populationsebene und erfordern Omics-Daten, die in der klinischen Routineversorgung typischerweise nicht verfügbar sind. Das vorgeschlagene System arbeitet stattdessen mit individuellen Laborwerten des Patienten und liegt damit näher an klinischen Standardabläufen, auch wenn seine klinische Anwendbarkeit noch validiert werden muss.

7.3 Graphbasiertes klinisches Schließen

Wissensgraphen für die klinische Entscheidungsunterstützung wurden in verschiedenen Kontexten untersucht. Klinische Wissensgraphen aus elektronischen Gesundheitsakten (Rotmensch et al., 2017) erfassen statistische Assoziationen zwischen Diagnosen, Laborwerten und Behandlungen. Großskalige biomedizinische Wissensgraphen wie Hetionet (Himmelstein et al., 2017) integrieren diverse Datenquellen für Drug-Repurposing und Hypothesengenerierung. Keines dieser Systeme nutzt jedoch den Pathway-Status als primäre Einschränkung in der Ausschlusslogik.

7.4 LLM-gestütztes biomedizinisches Schließen

Neuere Arbeiten kombinieren große Sprachmodelle mit biomedizinischen Wissensgraphen. ESCARGOT (Matsumoto et al., 2025) integriert LLMs mit einer dynamischen „Graph of Thoughts“-Architektur und biomedizinischen Wissensgraphen für Multihop-Schlussfolgerungsaufgaben. Während ESCARGOT effektives graphbasiertes Schließen in biomedizinischen Kontexten demonstriert, arbeitet es als Allzweck-Schlussfolgerungsagent ohne explizite Ausschlusslogik. Das vorgeschlagene System teilt die Betonung des wissensgraphgesteuerten Schließens, unterscheidet sich aber grundlegend in seinem Ordnungsprinzip: funktionelle Pathways als primäre diagnostische Einschränkungen statt allgemeiner Graphtraversierung.

HealthGenie (Gao et al., 2025) demonstriert wissensgetriebene LLM-Integration für personalisierte Gesundheitsberatung. Sein Ansatz organisiert Wissensgraphen um Benutzerprofile und Ernährungsempfehlungen – eine symptomzentrierte (oder bedarfszentrierte)

Organisation. Im Gegensatz dazu organisiert das vorgeschlagene System um biologische funktionelle Pathways, was eine mechanistische Ausschlusslogik ermöglicht, die in symptomzentrierten Architekturen nicht verfügbar ist.

7.5 Vergleichszusammenfassung

Tabelle 5: Vergleich des vorgeschlagenen Systems mit verwandten Ansätzen.

System	Primäre Entität	Ausschluss	Laborwerte	Pathways
Phenomizer	HPO-Phänotypen	Nein	Nein	Nein
PhenoTips	Patientenphänotypen	Nein	Begrenzt	Nein
GSEA/KEGG	Pathways	Nein	Nur Omics	Ja
Hetionet	Heterogen	Nein	Nein	Teilweise
Klinische KGs	EHR-Daten	Nein	Ja	Nein
ESCARGOT	KG + LLM	Nein	Nein	Teilweise
HealthGenie	KG + LLM	Nein	Nein	Nein
Vorgeschlagen	Pathways	Ja	Ja	Ja

8 Evaluationsframework

8.1 Benchmark-Datensatz

Eine rigorose Validierung erfordert einen kuratierten Benchmark von 20–50 bestätigten genetischen Diagnosen, bei denen:

1. Laborprofile des Patienten zum Zeitpunkt der Erstvorstellung (vor der genetischen Diagnose) vorliegen.
2. Die genetische Diagnose bestätigt ist (Variante + Phänotyp + funktionelle Studie).
3. Der Pathway-Status des Patienten retrospektiv aus Labordaten rekonstruiert werden kann.

Zielquellen umfassen Register für seltene Erkrankungen (EURORDIS), klinische Synopsen aus OMIM und publizierte Fallserien mit umfassenden Laboruntersuchungen.

8.2 Evaluations-Gate-Ledger

Das Evaluationsproblem ist kein einzelner Genauigkeitswert. Demonstrationsdaten, synthetische Stresstests, Realfall-Benchmarks, zeitliche Gültigkeit, Provenienz und externe Vergleichssysteme beantworten unterschiedliche Fragen. Tabelle 6 trennt diese Ebenen, damit ein positives Ergebnis in einer Schicht nicht als Validierung einer anderen Schicht überlesen wird.

Tabelle 6: Evaluationsgates für die Validierung von Pathway-Zertifikaten.

Gate	Minimales Datenobjekt	Pass-/Hold-Regel	Verhinderter Überclaim
Demonstrations-Seed	Kuratierter Hämolyse-Immundefizienz-Teilgraph mit manuell gesetzten Pathway-Statuswerten	Erwartete Kandidatenreduktionslogik wird reproduziert und plausible Krankheitsgene bleiben erhalten	Keine Schätzung klinischer Leistungsfähigkeit
Synthetische Stresstests	Eingepflanztes ursächliches Gen, simulierte Laborstörung und bekannte interne Grundwahrheit	Das ursächliche Gen wird nie ausgeschlossen; nicht-ursächliche Gene werden nur bei tragender Pathway-Logik zurückgestuft	Kein Ersatz für Realfallvalidierung
Realfall-Benchmark	20–50 bestätigte seltene Erkrankungsfälle mit Laborprofilen vor der genetischen Diagnose	$CRR \geq 0,30$ bei Falschausschlussrate = 0	Kein autonomer Diagnoseclaim
Temporales Zertifikatsgate	Altersfenster, Krankheitsstadium, Beobachtungszeitpunkt und Gültigkeitshorizont je Pathway-Zertifikat	Harter Ausschluss ist nur im gültigen Zeitfenster erlaubt; sonst ist Review erforderlich	Keine zeitlose Ausschlussregel
Provenienz und Evidenzstufe	Quellenkennung, Evidenzspanne, Datenbankversion und Konfidenzstufe je Pathway-Statusclaim	Jedes beibehaltene oder ausgeschlossene Gen ist auf explizite Quellevidenz rückführbar	Keine quellenfreie Graphinferenz
Comparator Suite	Derselbe Fallsatz für HPO/Phenomizer und reproduzierbare Rare-Disease-KG- oder Embedding-Baselines	Zusatznutzen gegenüber HPO-only-Filterung und aktuellen Baselines wird sichtbar	Kein isolierter Benchmarkclaim

8.3 Primäre Metrik

Die Kandidatenreduktionsrate (CRR, Gleichung (5)) dient als primäres Erfolgskriterium. Ein $CRR > 0,30$ unterstützt die Kernhypothese; ein $CRR < 0,10$ würde auf unzureichenden diagnostischen Mehrwert hinweisen.

Sicherheitseinschränkung: Das bestätigte ursächliche Gen darf *niemals* ausgeschlossen werden (Falschausschlussrate = 0). Jeder Falschausschluss im Benchmark invalidiert das Modell für die klinische Anwendung.

8.4 Alternative Validierung: Synthetische Patientenszenarien

Ein alternativer Validierungsweg trägt dem Mangel an annotierten realen Datensätzen für seltene Erkrankungen Rechnung. Synthetische Patientenszenarien können durch gezielte Störungen im Pathway-Graphen konstruiert werden – beispielsweise durch Simulation eines ANK1-Defekts, indem der Erythrozytenmembranintegritäts-Pathway auf „gestört“ gesetzt wird und intern konsistente Laborwerte abgeleitet werden. Da das ursächliche Gen *a priori* definiert ist, kann die Ausschluss-Engine mit exakter interner Grundwahrheit evaluiert werden: Das System sollte nicht-ursächliche Gene zurückstufen (Messung der CRR) und das eingepflanzte ursächliche Gen beibehalten (Messung der Falschausschlussrate). Dieser Ansatz ergänzt einen Realfall-Benchmark, kann ihn aber nicht ersetzen; er eignet sich dazu, die algorithmische Logik einem Stresstest zu unterziehen, nicht dazu, klinische Leistungsfähigkeit zu schätzen.

8.5 Sekundäre Metriken

- **Rangverbesserung:** Position des korrekten Gens in der ranggeordneten Kandidatenliste nach Ausschlussfilterung.
- **Abdeckung:** Prozentsatz der Benchmark-Fälle, bei denen mindestens ein Pathway anhand verfügbarer Labordaten bewertet werden kann.
- **Vergleich:** CRR gegenüber standardmäßiger HPO-only-Filterung auf dem gleichen Fallsatz.

9 Diskussion

Der Pathway-zentrierte Ansatz adressiert eine strukturelle Lücke in der aktuellen klinischen Entscheidungsunterstützung: die systematische Nutzung *negativer Evidenz* (was nachweislich funktioniert), um den diagnostischen Raum einzuschränken. Dies ist konzeptionell analog zur industriellen Fehlerdiagnose, bei der funktionierende Subsysteme ganze Äste des Fehlerbaums eliminieren.

Mehrere Designentscheidungen verdienen Diskussion:

Warum Pathways als Zentrum, nicht Gene oder Diagnosen? Gene sind Ursachen; Diagnosen sind Folgen. Keines von beiden bietet die mechanistische Zwischenschicht, die für ausschlussbasiertes Schließen benötigt wird. Pathways repräsentieren die funktionellen Einheiten, die genetische Ursachen mit klinischen Auswirkungen verbinden, und sind damit der natürliche Drehpunkt für sowohl Einschluss- als auch Ausschlusslogik.

Binärer vs. probabilistischer Ausschluss. Das binäre Modell ist konzeptionell einfacher und leichter zu validieren (ein Gen wird entweder beibehalten oder zurückgestuft), kann aber keine Unsicherheit ausdrücken. Das probabilistische Modell erfasst abgestufte Evidenz, erfordert jedoch kalibrierte Parameter. Wir behandeln deshalb das binäre Modell als initiales Validierungsziel und das probabilistische Modell als explorative Erweiterung.

Skalierbarkeit. Der aktuelle Prototyp bewältigt das Demonstrationsszenario (~50 Knoten, ~80 Kanten) ohne Leistungsprobleme. Die Skalierung auf die vollständige Reactome-Datenbank (>2400 Pathways, >10 000 Reaktionen) wird Leistungstests und wahrscheinlich eine Migration zu einer Graphdatenbank-Backend erfordern.

10 Fazit und zukünftige Arbeiten

Der funktionale Pathway-zentrierte Wissensgraph repräsentiert einen strukturell eigenständigen Ansatz zur Differentialdiagnoseforschung, der Pathway-Status-Evidenz als explizite diagnostische Einschränkungen nutzt. Die prototypische Implementierung demonstriert die Machbarkeit über alle Kernkomponenten hinweg: Datenaufnahme aus sechs öffentlichen Datenbanken, Graphmodellierung mit semantischen Kantentypen, binäre und probabilistische Ausschlusslogik, Mustererkennung und interaktive Visualisierung.

Die Kernhypothese – dass Pathway-Ausschluss den Kandidatengenraum um $\geq 30\%$ ohne Falschausschlüsse reduziert – ist testbar und stellt das primäre empirische Ziel für zukünftige Arbeiten dar.

10.1 Zentrale offene Aufgaben

1. **Benchmark-Datensatz:** Kuratierung von 20–50 Fällen aus Registern für seltene Erkrankungen mit Laborprofilen und bestätigten genetischen Diagnosen.
2. **Gewichtskalibrierung:** Entwicklung einer datengetriebenen Methode zur Schätzung der Pathway-Konfidenzgewichte $c(p_i)$ aus Messzuverlässigkeit und Pathway-Redundanz.
3. **OMIM/HPO-Integration:** Verknüpfung von Krankheits-Gen-Assoziationen aus OMIM und HPO-Annotationen, um einen direkten Vergleich mit rein phänotypbasierter Filterung zu ermöglichen.
4. **Graphdatenbank-Migration:** Evaluation von Neo4j oder ähnlichen Backends für Skalierbarkeit über den SQLite-Prototyp hinaus.
5. **Vergleich mit klinischen Werkzeugen:** Benchmark gegen Phenomizer auf demselben Fallsatz zur Quantifizierung des Mehrwerts der Pathway-zentrierten Ausschlusslogik.
6. **Temporale Modellierung:** Erweiterung des Frameworks zur Erfassung der Krankheitsprogression und zeitabhängiger Pathway-Statusänderungen.

Daten- und Softwareverfügbarkeit

Der Quellcode des Prototyps, einschließlich Datenbankschema, Aufnahmepipelines, Ausschluss-Engines und GUI-Anwendung, ist im [öffentlichen GitHub-Repository](#) verfügbar. Das System integriert ausschließlich öffentliche Datenquellen; es werden keine Patientendaten verwendet oder benötigt.

KI-Nutzungserklärung

Bei der Erstellung dieses Manuskripts wurden KI-gestützte Werkzeuge (Claude/Anthropic und GPT/Codex) als nicht-autorschaftliche Hilfsmittel eingesetzt, insbesondere für Literaturorganisation, Code-Unterstützung, Textstrukturierung, Übersetzungshilfe, Konsistenzprüfung und LaTeX-/PDF-Qualitätssicherung. Diese Werkzeuge hatten keine Autorenschaft, keine Koautorrolle, keine Danksagungsempfängerrolle, keine Wahrheits- oder Ground-Truth-Funktion und keine Rolle als unabhängige Validierungsinstanz. Die inhaltliche Konzeption, wissenschaftliche Argumentation, formale Modellentwicklung, finalen redaktionellen Entscheidungen und Verantwortung für den gesamten Inhalt liegen ausschließlich beim Autor.

Literatur

Amberger, J. S., Bocchini, C. A., Scott, A. F., and Hamosh, A. (2019). OMIM.org: leveraging knowledge across phenotype–gene relationships. *Nucleic Acids Research*, 47(D1):D1038–D1043.

- Ashburner, M., Ball, C. A., Blake, J. A., Botstein, D., Butler, H., Cherry, J. M., Davis, A. P., Dolinski, K., Dwight, S. S., Eppig, J. T., Harris, M. A., Hill, D. P., Issel-Tarver, L., Kasarskis, A., Lewis, S., Matese, J. C., Richardson, J. E., Ringwald, M., Rubin, G. M., and Sherlock, G. (2000). Gene Ontology: tool for the unification of biology. *Nature Genetics*, 25(1):25–29.
- Braschi, B., Denny, P., Gray, K., Jones, T., Seal, R., Tweedie, S., Yates, B., and Bruford, E. (2019). Genenames.org: the HGNC and VGNC resources in 2019. *Nucleic Acids Research*, 47(D1):D786–D792.
- Diehl, A. D., Meehan, T. F., Bradford, Y. M., Brush, M. H., Dahdul, W. M., Dougall, D. S., He, Y., Osumi-Sutherland, D., Ruttenberg, A., Sarntivijai, S., Van Slyke, C. E., Vasilevsky, N. A., Haendel, M. A., Blake, J. A., and Mungall, C. J. (2016). The Cell Ontology 2016: enhanced content, modularization, and ontology interoperability. *Journal of Biomedical Semantics*, 7(1):44.
- Dzhafarov, E. N. and Kujala, J. V. (2016). Context-content systems of random variables: The contextuality-by-default theory. *Journal of Mathematical Psychology*, 74:11–33.
- Fabregat, A., Jupe, S., Matthews, L., Sidiropoulos, K., Gillespie, M., Garapati, P., Haw, R., Jassal, B., Korninger, F., May, B., Milacic, M., Duenas Roca, C., Rothfels, K., Sevilla, C., Shamovsky, V., Shorser, S., Varusai, T., Viteri, G., Weiser, J., Wu, G., Stein, L., Hermjakob, H., and D’Eustachio, P. (2018). The Reactome pathway knowledgebase. *Nucleic Acids Research*, 46(D1):D649–D655.
- Gao, F., Zhao, X., Xia, D., Zhou, Z., Yang, R., Lu, J., Jiang, H., Park, C., and Li, I. (2025). HealthGenie: A knowledge-driven LLM framework for tailored dietary guidance. In *Proceedings of the 34th ACM International Conference on Information and Knowledge Management*, CIKM ’25, pages 6639–6643. ACM.
- Girdea, M., Dumitriu, S., Fiume, M., Bowdin, S., Boycott, K. M., Chénier, S., Chitayat, D., Faghfoury, H., Meyn, M. S., Ray, P. N., So, J., Stavropoulos, D. J., and Brudno, M. (2013). PhenoTips: Patient phenotyping software for clinical and research use. *Human Mutation*, 34(8):1057–1065.
- Himmelstein, D. S., Lizee, A., Hessler, C., Brueggeman, L., Chen, S. L., Hadley, D., Green, A., Khankhanian, P., and Baranzini, S. E. (2017). Systematic integration of biomedical knowledge prioritizes drugs for repurposing. *eLife*, 6:e26726.
- HL7 International (2023). FHIR release 5. <https://hl7.org/fhir/R5/>. Accessed: 2026-03-16.
- Kanehisa, M., Furumichi, M., Sato, Y., Kawashima, M., and Ishiguro-Watanabe, M. (2023). KEGG for taxonomy-based analysis of pathways and genomes. *Nucleic Acids Research*, 51(D1):D587–D592.
- Köhler, S., Schulz, M. H., Krawitz, P., Bauer, S., Dölken, S., Ott, C. E., Mundlos, C., Horn, D., Mundlos, S., and Robinson, P. N. (2009). Clinical diagnostics in human genetics with semantic similarity searches in ontologies. *American Journal of Human Genetics*, 85(4):457–464.

- Matsumoto, N., Choi, H., Moran, J., Hernandez, M. E., Venkatesan, M., Li, X., Chang, J.-H., Wang, P., and Moore, J. H. (2025). ESCARGOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning. *Bioinformatics*, 41(2).
- Mungall, C. J., Torniai, C., Gkoutos, G. V., Lewis, S. E., and Haendel, M. A. (2012). Uberon, an integrative multi-species anatomy ontology. *Genome Biology*, 13(1):R5.
- Robinson, P. N., Köhler, S., Bauer, S., Seelow, D., Horn, D., and Mundlos, S. (2008). The Human Phenotype Ontology: a tool for annotating and analyzing human hereditary disease. *American Journal of Human Genetics*, 83(5):610–615.
- Rotmensch, M., Halpern, Y., Tlimat, A., Horng, S., and Sontag, D. (2017). Learning a health knowledge graph from electronic medical records. *Scientific Reports*, 7(1):5994.
- Subramanian, A., Tamayo, P., Mootha, V. K., Mukherjee, S., Ebert, B. L., Gillette, M. A., Paulovich, A., Pomeroy, S. L., Golub, T. R., Lander, E. S., and Mesirov, J. P. (2005). Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles. *Proceedings of the National Academy of Sciences*, 102(43):15545–15550.
- The UniProt Consortium (2023). UniProt: the Universal Protein Knowledgebase in 2023. *Nucleic Acids Research*, 51(D1):D523–D531.